

פתרון מטלה 3 – חישוביות וקוגניציה, 6119

19 בנובמבר 2025



שאלת הכנה

סעיף א'

תהי $f: \mathbb{R}^m \rightarrow \mathbb{R}$ אשר מקבל משתנה מקרי \bar{x} . נניח שפרספטרון לינארי מנסה ללמוד את f עם x באלגוריתם Batch יחד עם פונקציית שגיאה כלשהי. נסמן ב- \bar{w} את תוצאת הלמידה אחרי n צעדי עדכון, ונבדוק מה משפיע על שגיאת ההכללה $\varepsilon_g(\bar{w})$. פתרון נניח ש- $\varepsilon: \mathbb{R}^{m+1} \rightarrow \mathbb{R}_{\geq 0}$ פונקציית השגיאה, אז בהגדרה,

$$\varepsilon_g(\bar{w}) = \mathbb{E}(\bar{w}\bar{x}, f(\bar{x}))$$

ולכן ε_g תלוי ב- f (תשובה א'), בפונקציית השגיאה שנבחרה (תשובה ב') התפלגות \bar{x} (תשובה ג'). נשים לב שידוע כי $L \xrightarrow{n \rightarrow \infty} \varepsilon_g$ ולכן יש תלות גם ב- \bar{w}^0 (תשובה ד') וב- n (תשובה ז').

נבחין כי כתלות במימד ובבחירת דוגמות אופטימלית נוכל גם להשפיע על השגיאה להיות מינימלית (על-ידי כופלי לגרנז' או גזירה) ולכן גם מספר הדוגמות יכול להשפיע וכן הדוגמות הספציפיות שנבחרו (כלומר תשובות ה' וו'), אבל זוהי הנחה נוספת שאין לנו סיבה להניח בתנאי השאלה.

סעיף ב'

נתונות שתי פונקציות $f, g: \mathbb{R}^3 \rightarrow \mathbb{R}$ המוגדרות על-ידי,

$$f(x_1, x_2, x_3) = x_1^2 + 2x_2 - x_3, \quad g(x_1, x_2, x_3) = 3x_1^2 + 2x_2 + 1$$

נבדוק מה ניתן לומר על וקטורי הגרדיאנט של f, g ב- $x_0 \in \mathbb{R}^3$ כך ש- $x_i \neq 0, \forall i \leq 3$. פתרון מתקיים,

$$\nabla f(x) = (2x_1, 2, -1), \quad \nabla g(x) = (6x_1, 2, 0)$$

ולכן מההנחה מתקיים $2x_1 \neq 6x_1$ וכן $-1 \neq 0$, לכן הם שונים באיבר השלישי והראשון (תשובה ב'). אם נניח רק ש- $x \neq 0$ אז הם שונים ברכיב אחד במקרה שבו $x_1 = 0$.

סעיף ג'

תהי רשת נוירונים לינאריים מארכיטקטורה לא ידועה שמנסה ללמוד פונקציה לא לינארית בעזרת אלגוריתם online, נבדוק מה נכון במקרה זה. פתרון אם קצב הלימוד η גדול ביחס לגרדיאנט ולמרחק מהמינימום המקומי אז לא מובטחת התכנסות, כלומר הגעה לשגיאה אופטימלית תדרוש הרבה זמן (תשובה ב'). נניח שאנחנו מאמנים כמות נתונה של פעמים על דוגמות ספציפיות אז הקטנת η תיעל את תהליך האימון (תשובה ג').

שאלה 1

תהי $f: \mathbb{R}^4 \rightarrow \mathbb{R}$ המוגדרת על-ידי $f(x) = x^t \cdot x + a^t \cdot x$ כאשר $a = (2, 4, 8, 16)^t$.

סעיף א'

נסמן $x_0 = 1$ ונחשב את $f(x_0)$.
פתרון מתקיים $f(x_0) = f(1) = 1 \cdot 1 + a \cdot 1 = 2 + 4 + 8 + 16 = 30$ כאשר $1 \in \mathbb{R}^4$ וקטור סקלרי.

סעיף ב'

נחשב את הגרדיאנט של f וכן את ערכו ב- x_0 .
פתרון מתקיים,

$$\nabla f(x) = D(x^t x + a^t x) = 2x + a$$

בכתיבה וקטורית, קרי $\nabla f(x_1, x_2, x_3, x_4) = (2x_1 + a_1, 2x_2 + a_2, 2x_3 + a_3, 2x_4 + a_4)$. בהתאם גם $\nabla f(1) = 2 \cdot 1 + a = a + 2 = (4, 6, 10, 18)^t$.

סעיף ג'

נבדוק את $f(x_0 + \varepsilon) - f(x_0)$ עבור,
 $\varepsilon^1 = (0.1, 0.2, 0.1, 0.2)^t$, $\varepsilon^2 = (0.1, 0.2, 0.2, 0.1)^t$, $\varepsilon^3 = (0.2, 0.2, 0.1, 0.1)^t$

פתרון נבחין כי $\|x_0 + \varepsilon^i\|^2 = 5.3$ וכן $f(x_0) = 30$ ולכן,
 $f(x_0 + \varepsilon^1) - f(x_0) = 5.3 + a^t(x_0 + \varepsilon^1) - 30 = 5.3 - a^t \varepsilon^1 = 0.3$
ולכן באופן דומה נקבל שגם $f(x_0 + \varepsilon^2) - f(x_0) = 1.1$ וגם $f(x_0 + \varepsilon^3) - f(x_0) = 1.7$.

סעיף ד'

נחשב את הזווית בין ε^i ל- $\nabla f(x_0)$.
פתרון לכל $1 \leq i \leq 3$,

$$\theta(\nabla f(x_0), \varepsilon^i) = \arccos \left(\frac{\nabla f(x_0) \cdot \varepsilon^i}{\|\nabla f(x_0)\| \cdot \|\varepsilon^i\|} \right) = \arccos \left(\frac{(4, 6, 10, 18) \cdot \varepsilon^i}{6.89927532426 \dots} \right)$$

ולכן מהצבה במחשבון נקבל,

$$\theta(\nabla f(x_0), \varepsilon^1) = 0.454125247397 \dots, \quad \theta(\nabla f(x_0), \varepsilon^2) = 0.67181883632 \dots, \quad \theta(\nabla f(x_0), \varepsilon^3) = 0.801367264691 \dots$$

סעיף ה'

נסביר את המגמה שהתקבלה בין הפרשי f מסעיף ג' לבין הזוויות מסעיף ד'.
פתרון קיבלנו שהזווית היא הקטנה ביותר כשהפרש הוא הקטן ביותר, זה לא מפתיע שכן חישובנו קירוב של נגזרת כיוונית ל- ε^1 בסעיף ב' ובסעיף ד' חישובנו קירוב כזה שוב (שכן זווית מוגדרת על-ידי נרמול).

סעיף ו'

נמצא ε כך ש- $f(x_0 + \varepsilon) - f(x_0)$ יהיה מקסימלי, כאשר $\|\varepsilon\| = \|\varepsilon^1\|$.

פתרון מצאנו ש- $\nabla f(x_0) = (4, 6, 10, 18)^t$, לכן כהעתקה לינארית נקבל את העלייה הגבוהה ביותר בווקטור הכיוון $\frac{\nabla f(x_0)}{\|\nabla f(x_0)\|}$, התבקשנו לחשב עבור ε עם נורמה $\|\varepsilon^1\|$, ולכן נקבל,

$$\varepsilon = \frac{\nabla f(x_0)}{\|\nabla f(x_0)\|} \cdot \|\varepsilon^1\| \approx (0.0579, 0.086, 0.144, 0.2608)^t$$

סעיף ז'

נכתוב את הקשר שבין הסעיפים הקודמים לבין האלגוריתם של למידת גרדיאנט.

פתרון בלמידת גרדיאנט אנו למעשה מחשבים את הגרדיאנט במטרה למצוא וקטור כיוון מקסימלי במטרה לקחת את הווקטור המנוגד לו, הגודל $\|\varepsilon^1\|$ הוא למעשה η , קבוע הלמידה. נעבור לחלק ב' של השאלה.

סעיף א'

עבור $x, \varepsilon_0 \in \mathbb{R}^n$ נפתח את פולינום טיילור שלהם מסדר ראשון לערך $f(x + \varepsilon)$.

פתרון מהגדרה נקבל שפיתוח סביב x_0 הוא $P_1(x) = f(x_0) + Df|_{x_0}(x - x_0)$, לכן בפרט גם $P_1(x_0 + \varepsilon) = f(x_0) + Df|_{x_0}\varepsilon$.