

תורת ההסתברות 2 – סיכום

4 ביולי 2026



תוכן העניינים

3	שיעור 1 – 25.3.2026	1
3	1.1 מבוא הקורס	
4	1.2 פרקולציה	
5	שיעור 2 – 15.4.2026	2
5	2.1 ממידה להסתברות	
8	שיעור 3 – 29.4.2026	3
8	3.1 משתנים מקריים	
10	שיעור 4 – 6.5.2026	4
10	4.1 התכנסות	
10	4.2 החוק החזק והחלש של המספרים הגדולים	
13	שיעור 5 – 13.5.2026	5
13	5.1 התכנסות – המשך	
13	5.2 פרדוקס המעטפות	
14	5.3 משפט הקירוב של ויירשטראס	
14	5.4 הימורים	
15	5.5 אי-תלות בזוגות	
16	שיעור 6 – 20.5.2026	6
16	6.1 שרשרות מרקוב	
18	שיעור 7 – 27.5.2026	7
18	7.1 שרשרות מרקוב	
20	שיעור 8 – 3.6.2026	8
20	8.1 שרשרות מרקוב	
20	8.2 צימודים	
21	8.3 פילטרציה	
22	שיעור 9 – 10.6.2026	9
22	9.1 מרטינגלים	
22	9.2 תוחלת מותנית	
23	9.3 מרטינגלים ותוחלת מותנית	
25	שיעור 10 – 17.6.2026	10
25	10.1 מרטינגלים	
27	שיעור 11 – 29.6.2026	11
27	11.1 מרטינגלים – המשך	

25.3.2026 – 1 שיעור 1

1.1 מבוא הקורס

הקורס מבוסס על הספר Williams של Probability with Martingales. במהלך הקורס נלמד שלושה נושאים, קצת סותרים באיזשהו מובן. נתחיל מללמוד הסתברות בהתבסס על תורת המידה, כך נבסס תוצאות שנלמדו בקורס הקודם. בחלק השני נלמד נושאים מתקדמים בהסתברות, כדוגמת משפט הגבול המרכזי (אותו ראינו אבל לא הוכחנו), פורייה מרטינגלים ושרשרות מרקוב. בחלק האחרון נגיע לנושאים ומחקר בעולם ההסתברות, נלמד על הילוכים מקריים, פרקליציה וכן הלאה.

נעבור לדוגמות דווקא מהחלק האחרון, כדי להדגים רעיונות אותם אנו רוצים לראות.

דוגמה 1.1 (הילוכים מקריים) באנגלית (Simple) Random Walk. יהיו $X_1, X_2, \dots$ משתנים מקריים שווים-התפלגות כך ש- $X_n \sim U(\{-1, 1\})$ ונגדיר $Y_n = \sum_{i=1}^n X_i$. הסיבה שאנחנו קוראים למושג הזה הילוך היא שהערכים המתקבלים מהסכימה מהלכים על הישר הממשי, אנו מעוניינים לשאול שאלות כמו $\mathbb{P}(Y_n = 0) = 0$ או גם יכולים לבדוק את הערך $\mathbb{P}(\exists n > 0 \ Y_n = 0)$, ברור כי ערך זה הוא לפחות חצי שכן הוא מקיים $\mathbb{P}(Y_2 = 0) = \frac{1}{2} \geq \mathbb{P}(Y_n = 0)$. למעשה ערך זה שווה ל-1, $\lim_{m \rightarrow \infty} \mathbb{P}(\exists 0 < n < m \ Y_n = 0) = 1$, ונאמר שבמקרה זה ההילוך המקרי נשנה. אם X_n היו מתפלגים אחרת, לדוגמה עבור $\mathbb{P}(X_n = 1) = p$ אז $0 \leq p \leq 1$ או $\mathbb{P}(\exists n > 0 \ Y_n = 0) < 1$.

נבחן את $\mathbb{P}(Y_{2n} = 0)$ זוהי ההסתברות שיש בדיוק n משתנים X_k המקבלים 1,

$$\begin{aligned} \mathbb{P}(Y_{2n} = 0) &= \mathbb{P}(\exists I \subseteq [2n], |I| = n \ \forall i \ X_i = 1 \iff i \in I) \\ &= \sum_{|I|=n, I \subseteq [2n]} \mathbb{P}(\forall i \ X_i = 1 \iff i \in I) \\ &= \sum_{|I|=n, I \subseteq [2n]} \frac{1}{2^{2n}} \\ &= \binom{2n}{n} \cdot \frac{1}{2^{2n}} \\ &= \frac{(2n)!}{(n!)^2 2^{2n}} \\ &\stackrel{(1)}{\approx} \frac{\sqrt{2\pi} \cdot 2n \left(\frac{2n}{e}\right)^{2n}}{\left(\sqrt{2\pi n} \left(\frac{n}{e}\right)^n\right)^2 \cdot 2^{2n}} \\ &= \frac{\sqrt{4\pi n}}{2\pi n} = \frac{1}{\sqrt{\pi n}} \end{aligned}$$

כאשר (1) נובע מנוסחת סטירלינג, כלומר ש- $k! \approx \sqrt{2\pi k} \left(\frac{k}{e}\right)^k$. לכן $\sum_{n=1}^{\infty} \mathbb{P}(Y_{2n} = 0) = \infty$. קיבלנו את התוצאה שמספר החזרות לראשית הוא אינסופי.

נעבור למקרה $\mathbb{P}(X_i = 1) = p > \frac{1}{2}$. אי-שוויון הופדינג טוען שאם $Z_1, \dots, Z_n$ משתנים מקריים בלתי-תלויים עם $\mathbb{E}(Z_i) = 0$ לכל i וכן ש- $|Z_i| \leq 1$ אז לכל $a > 0$ מתקיים,

$$\mathbb{P}\left(\sum_{i=1}^n Z_i \geq a\right) \leq \exp\left(-\frac{a^2}{2n}\right)$$

צ'בישב היה נותן לנו חסם $\leq \frac{n}{a^2}$ במקום. נגדיר $Z_i = \frac{X_i - (2p-1)}{2}$ כדי לנרמל ונקבל שמתקיים $\sum_{i=1}^k Z_i = \frac{1}{2} \sum_{i=1}^k X_i - n(p - \frac{1}{2})$ אז

מתקיים,

$$\begin{aligned}
 \mathbb{P}(Y_n = 0) &= \mathbb{P}\left(\sum_{i=1}^n X_i = 0\right) \\
 &= \mathbb{P}\left(\sum_{i=1}^n Z_i = -n\left(p - \frac{1}{2}\right)\right) \\
 &\leq \mathbb{P}\left(\sum_{i=1}^n -Z_i \geq n\left(p - \frac{1}{2}\right)\right) \\
 &\leq \exp\left(-\frac{n^2\left(p - \frac{1}{2}\right)^2}{2n}\right) \\
 &= \exp\left(-\frac{\left(p - \frac{1}{2}\right)^2}{2} \cdot n\right)
 \end{aligned}$$

כלומר ההסתברות דועכת אקספוננציאלית, ובהתאם $\sum_{n=1}^{\infty} \mathbb{P}(Y_n = 0) < \infty$. מצאנו שיש הבדל מהותי בין המקרים $p = \frac{1}{2}$ והמקרים $p \neq \frac{1}{2}$. אם נסמן $q = \mathbb{P}(\forall n > 0 \ Y_n = 0)$, כלומר ההסתברות שלעולם לא נחזור לאפס. התפלגות מספר החזרות לראשית היא גאומטרית $\text{Geo}(q)$. אם $q = 0$ אז בהסתברות 1 חוזרים לראשית אינסוף פעמים. אם $q > 0$ אז תוחלת מספר החזרות לראשית היא $\frac{1}{q} < \infty$. כש- $p = \frac{1}{2}$ התוחלת היא אינסוף ואחרת התוחלת סופית. לכן אם $p = \frac{1}{2}$ אז $q = 0$ (נשנה) ואם $p \neq \frac{1}{2}$ אז $q > 0$ (חולף). זוהי לא הוכחה פורמלית, אבל היא מבהירה לנו את הקונספט הכללי עליו אנו מדברים.

הגדרה 1.1 (הילוך מקרי פשוט על גרף) באנגלית Simple Random Walk או SRW על גרף. נניח ש- $G = (V, E)$ גרף פשוט וקשיר עם דרגות סופיות ויהי v_0 קודקוד כלשהו. SRW היא סדרת קודקודים מקריים בגרף, כאשר $X_0 = v_0$ כמעט תמיד, בהינתן ש- $X_0 = v_0, X_1 = v_1, \dots, X_n = v_n$ מגרילים באופן אחיד בין השכנים של v_n .

דוגמה 1.2 עתה נוכל לדבר על $q = \mathbb{P}(\forall n > 0 \ X_n \neq v_0)$, כלומר הפעם ההילוך הוא לאורך גרף, אם $q = 0$ אז ההילוך נשנה ואם $q > 0$ אז ההילוך חולף.

אם $G = \mathbb{Z}^2$ אז ההילוך נשנה, כדי להראות זאת עלינו להראות שתוחלת מספר החזרות לראשית הוא אינסופי, נבחין כי $\sum_{n=1}^{\infty} \mathbb{P}(X_n = v_0) = \infty$ שכן $\mathbb{P}(X_n = v_0) \approx \frac{c}{n}$. כדי לפתור את הבעיה הזו אנו נבחן את המקרה שבו ההילוך הוא בלתי תלוי על שני הצירים, התוצאה תהיה תנועה על רשת מסוימת שנראית בדיוק כמו $\mathbb{Z}^2$, ולכן נקבל את המבוקש כמכפלה של בלתי-תלויים.

מה יקרה במקרה $G = \mathbb{Z}^d$ עבור $d > 2$? השיטה של $d = 2$ לא עובדת יותר, אבל הטענה עדיין נכונה, כלומר $\mathbb{P}(X_n = v_0) \approx \frac{c}{n^{\frac{d}{2}}}$ ולכן $\sum_{n=1}^{\infty} \mathbb{P}(X_n = v_0) = \infty$ ולכן ההילוך חולף.

מה שראינו עתה הוא תוצאה בסיסית אחת בעולם שלם. באופן כללי האם גרף הוא נשנה או לא היא תכונה של הגרף ולא של נקודת ההתחלה.

1.2 פרקולציה

נעבור לנושא אחר אך קשור. נניח שיש לנו גרף G קשיר ואינסופי, לדוגמה $\mathbb{Z}^2$. לכל קשת נגריל בהסתברות p צביעה בכחול או אדום, באופן בלתי תלוי. יש לנו כמה שאלות שאנחנו יכולים לשאול, לדוגמה מה ההסתברות שהגרף הכחול קשיר, הסתברות זו היא 0 אם $p < 1$, זאת שכן ההסתברות שנקודה כלשהי נתונה היא מבודדת היא $1 - p^4$. נעבור לשאלה מה ההסתברות שבגרף הכחול יש רכיב קשירות אינסופי, זוהי שאלה מורכבת הרבה יותר, נסמן $\theta(p)$ כהסתברות ביחס ל- p , ונבחין ש- θ היא מונוטונית עולה חלש. יהיו $0 \leq p_1 < p_2 \leq 1$ ונצבע כל קשת בהסתברות p_1 בכחול כהה, בהסתברות $p_2 - p_1$ נצבע בכחול בהיר וב- $1 - p_2$ לא נצבע בכלל. אם נבחן את $\theta(p_1)$ נקבל את המצב המקורי עם p_1 , אם נבחן את שני גווני הכחול נקבל את $\theta(p_2)$, נגדיר את המורע A להיות קיום רכיב קשירות אינסופי כחול בהיר ו- B רכיב קשירות כזה כחול (שני הגווני). אז $A \subseteq B$ ולכן $\theta(p_1) = \mathbb{P}(A) \leq \mathbb{P}(B) = \theta(p_2)$. נקרא לרעיון זה צימוד (Coupling). משפט קולומורוב אומר שאם A מאורע זנב (לא מושפע משום קבוצה סופית של קורדינטות) אז $\mathbb{P}(A) \in \{0, 1\}$, נסיק ש- $\theta(p) \in \{0, 1\}$ ומונוטונית ונסמן את נקודת השינוי ב- p_c . האם $0 < p_c < 1$? מה ערך $\theta(p_c)$? אלו הן שאלות שאנו עדיין לא יכולים לענות עליהן עכשיו. אם $G = \mathbb{Z}$ אז $p_c = 1$. התשובה היא ש- $\theta(\frac{1}{2}) = 0$, עבור $G = \mathbb{Z}^2$ $p_c = \frac{1}{2}$. וזה מקרה נדיר שבו יש לנו ערך ולא רק חסם כללי.

2 שיעור 2 – 15.4.2026

2.1 מדידה להסתברות

ענה כשאנו מכירים את תורת המדידה, אנו יכולים לבסס מחדש את תורת ההסתברות עם כלים של מדידה, לדוגמה מרחב הסתברות הוא מרחב מדידה כש- $\mu(\Omega) = 1$. בנוסף נגדיר שמשנתה מקרי $X : \Omega \rightarrow \mathbb{R}$ כפונקציה מדידה. נאמר גם שנעסוק רק בקבוצות מדידות בורל. גם הגדרנו את $\mathbb{P}_X(S) = \mathbb{P}(X^{-1}(S))$ להיות התפלגות X , וכן $\int_{\mathbb{R}} 1 d\mathbb{P}_X = \int_{\Omega} X d\mathbb{P} = \mathbb{E}(X)$. ענה ניגש למלאכה הפורמלית. נניח מעתה ש- Ω קבוצה לא ריקה

הגדרה 2.1 (אלגברה) $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ היא אלגברה על Ω אם מתקיים,

$$1. \emptyset \in \mathcal{F}$$

$$2. \text{ לכל } A \in \mathcal{F} \text{ גם } A^C \in \mathcal{F}$$

$$3. \mathcal{F} \text{ סגורה לאיחוד זר סופי}$$

נאמר ש- $\mathcal{F}$ היא σ -אלגברה אם היא סגורה לאיחוד זר בן-מניה.

הגדרה 2.2 (מרחב מדיד) $(\Omega, \mathcal{F})$ מרחב מדיד $(\Omega, \mathcal{F})$ הוא קבוצה Ω ו- σ -אלגברה עליה.

דוגמה 2.1 איחודים סופיים של קטעים $(a, b) \subseteq (0, 1]$ היא אלגברה.

דוגמה 2.2 עבור $\Omega = \{0, 1\}^{\mathbb{N}}$ איחודים סופיים של קבוצות צילינדריים, כלומר,

$$\forall a \in \{0, 1\}^{\mathbb{N}}, \quad C_a = \{x \in \Omega \mid \forall 1 \leq i \leq n, x = a_i\}$$

היא אלגברה. במקרה זה לדוגמה $C_{0,1,0}$ היא קבוצת כל הסדרות שמתחילות ברישא $(0, 1, 0)$.

הגדרה 2.3 (סיגמא-אלגברה נוצרת) לכל $S \subseteq \mathcal{P}(\Omega)$ נגדיר את $\sigma(S)$ להיות ה- σ -אלגברה המינימלית שמכילה את S .

נבחין כי האופן שקול אפשר להגדיר את ה- σ -אלגברה הנוצרת באופן קונסטרוקטיבי.

דוגמה 2.3 עבור $S = \{A\}$ מתקיים $\sigma(S) = \{\emptyset, A, A^C, \Omega\}$.

דוגמה 2.4 עבור $A \subseteq \mathbb{N}$ נאמר שיש לה צפיפות $a \in [0, 1]$ אם,

$$\lim_{n \rightarrow \infty} \frac{|A \cap [n]|}{n} = a$$

נגדיר את $\mathcal{F}$ כאוסף כל הקבוצות בעלות צפיפות, האם $\mathcal{F}$ היא σ -אלגברה? התשובה היא שלא שכן כל יחידון הוא בעל צפיפות. האם $\mathcal{F}$ היא אלגברה?

הגדרה 2.4 (מידת הסתברות) בהינתן מרחב מדיד $(\Omega, \mathcal{F})$, כלומר $\mathcal{F}$ היא σ -אלגברה, פונקציה $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ היא מידת הסתברות אם,

$$1. \mathbb{P}(\emptyset) = 0$$

$$2. \mathbb{P}(A) \geq 0 \text{ לכל } A \in \mathcal{F}$$

$$3. \sigma\text{-אדיטיביות: אם } \{A_n\}_{n=1}^{\infty} \text{ זרות וז } \mathbb{P}(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$$

$$4. \mathbb{P}(\Omega) = 1$$

אם μ מוגדרת על אלגברה $\mathcal{F}$ ומקיימת סגירות לאיחוד זר בן-מניה אז נקרא לה **קדם-מידה**.

משפט 2.5 (הרחבה של קרתאודורי) אם $\mathcal{F}_0$ אלגברה על Ω ו- μ_0 קדם-מידה סופית או קיימת מידה יחידה וסופית μ על $\mathcal{F} = \sigma(\mathcal{F}_0)$ שמרחיבה את μ_0 .

דוגמה 2.5 עבור $\Omega = \{0, 1\}^{\mathbb{N}}$ ו- $\mathcal{F}_0$ האיחודים הסופיים של צילינדריים, $\mathcal{F} = \sigma(\mathcal{F}_0)$ נגדיר,

$$\forall a \in \Omega^{<\omega}, \quad \mu(C_a) = 2^{-|a|}$$

כלומר נקבל את האורך של הסדרה הסופית a , ונקבל את ההסתברות של הטלת מטבע מספר סופי של פעמים וקבלת הסדרה a . המשפט נותן לו מידת הסתברות μ המרחיבה את μ_0 . ענה נוכל לדבר על מאורעות ממידה אפס.

מה הקשר בין μ למידת לבג על $(0, 1]$? התשובה היא שהמידה של סדרה שווה למידה שלו כמספר בייצוג בינארי עשרוני במידת לבג, ואלו מרחבים שקולים עד כדי מידה 0.

הגדרה 2.6 (גבול עליון ותחתון של מאורעות) עבור $\{A_n\}_{n=1}^\infty \subseteq \mathcal{F}$ סדרת מאורעות (מידות) נגדיר,

$$\limsup A_n = \bigcap_{m=1}^\infty \bigcup_{n=m}^\infty A_n, \quad \liminf A_n = \bigcup_{m=1}^\infty \bigcap_{n=m}^\infty A_n$$

ההצדקה להגדרה זו היא שאם נגדיר את סדרת הפונקציות $\mathbb{1}_{A_n}$ אז נקבל,

$$\limsup_{n \rightarrow \infty} \mathbb{1}_{A_n} = \mathbb{1}_{\limsup_{n \rightarrow \infty} A_n}$$

ניזכר במספר טענות,

למה 2.7 (הראשונה של בורל-קנטלי) אם $\{A_n\}_{n=1}^\infty$ כך ש- $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) < \infty$ אז $\mathbb{P}(\lim_{n \rightarrow \infty} A_n) = 0$.

נראה דוגמה נגדית לגרירה ההפוכה,

דוגמה 2.6 אם נבחר את $A_n = [0, \frac{1}{n}]$ אז נקבל $\mathbb{P}(A_n) = \frac{1}{n}$ ולכן הסכום מתבדר אבל גם $\limsup_{n \rightarrow \infty} A_n = \{0\}$ ומהסתברות 0.

למה 2.8 אם $\{A_n\}_{n=1}^\infty \subseteq \mathcal{F}$ מאורעות בלתי-תלויים כך ש- $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) = \infty$ אז $\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = 1$.

בקורס הקודם הגדרנו אי-תלות בדרך ישירה,

הגדרה 2.9 (אי-תלות של מאורעות) אם $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{F}$ סדרת מאורעות, אז נאמר שהיא בלתי-תלויה אם לכל $I \subseteq \mathbb{N}$ סופית מתקיים,

$$\mathbb{P}\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} \mathbb{P}(A_i)$$

אבל נוכל להרחיב את ההגדרה לאי-תלות כללית יותר,

הגדרה 2.10 (אי-תלות סיגמא-אלגברה) אם $(\Omega, \mathcal{F}, \mathbb{P})$ מרחב הסתברות ו- $\mathcal{F}_1, \mathcal{F}_2$ הן תת- σ -אלגברות, אז נאמר שהן בלתי-תלויות אם לכל $A_1 \in \mathcal{F}_1, A_2 \in \mathcal{F}_2$ מתקיים,

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2)$$

מאורעות A_1, A_2 יקראו בלתי-תלויים אם $\sigma(A_1)$ ו- $\sigma(A_2)$ הן בלתי-תלויות.

הגדרה 2.11 (אי-תלות קבוצת סיגמא-אלגברות) אם I קבוצת אינדקסים כלשהי, תת- σ -אלגברות במרחב, אז נאמר שהן בלתי-תלויות אם לכל $J \subseteq I$ סופית מתקיים ולכל בחירה של $A_j \in \mathcal{F}_j$ לכל $j \in J$ מתקיים,

$$\mathbb{P}\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} \mathbb{P}(A_j)$$

מאורעות $\{A_i\}_{i \in I}$ יקראו בלתי-תלויים אם $\{\sigma(A_i)\}_{i \in I}$ בלתי-תלויה.

נחזור ללמה השנייה ונוכיח אותה.

הוכחה. נבחין כי מתקיים,

$$\limsup A_n = \left(\liminf A_n^C\right)^C$$

ולכן אנו רוצים להראות שמתקיים $\mathbb{P}(\liminf_{n \rightarrow \infty} A_n^C) = 0$, כלומר $\mathbb{P}(\bigcup_{m=1}^\infty \bigcap_{n=m}^\infty A_n^C) = 0$, אבל מרציפות,

$$\mathbb{P}\left(\bigcup_{m=1}^\infty \bigcap_{n=m}^\infty A_n^C\right) \leq \sum_{m=1}^\infty \mathbb{P}\left(\bigcap_{n=m}^\infty A_n^C\right)$$

אבל עבור סכומים חלקיים נקבל,

$$\lim_{m \rightarrow \infty} \mathbb{P}\left(\bigcap_{n=m}^M A_n^C\right) = \lim_{m \rightarrow \infty} \prod_{n=m}^M (1 - \mathbb{P}(A_n)) \leq \lim_{m \rightarrow \infty} \exp\left(-\sum_{n=m}^M \mathbb{P}(A_n)\right) \rightarrow 0$$

כאשר אי-השוויון האחרון נובע מאי-שוויון ברנולי $1 + x \leq e^x$. בהתאם קיבלנו את המבוקש. $\square$

הגדרה 2.12 (סיגמא-אלגברת זנב) נניח ש- $(\Omega, \mathcal{F})$ מרחב מדיד ו- $\{\mathcal{F}_n\}_{n \in \mathbb{N}}$ סדרת תת- σ -אלגברות. נגדיר את σ -אלגברת הזנב של $\{\mathcal{F}_n\}$ על-ידי,

$$\mathcal{T} = \bigcap_{m=1}^\infty \sigma(\mathcal{F}_m, \mathcal{F}_{m+1}, \dots)$$

כאשר נגדיר $\sigma(A_1, A_2, \dots) = \sigma(A_1 \cup A_2 \cup \dots)$. למאורע $A \in \mathcal{T}$ נקרא מאורע זנב.

הערה ההגדרה של σ -אלגברת זנב לא תלויה בסדר $\{\mathcal{F}_n\}$.

דוגמה 2.7 נגדיר שוב $\Omega = \{0, 1\}^{\mathbb{N}}$ וכן $\mathcal{F}_n = \sigma(B_n)$ כאשר $B_n = \{x \in \Omega \mid x_n = 0\}$. נבחין כי $A = \{(0, 0, \dots)\} \notin \mathcal{T}$, שכן אם $B \in \mathcal{T}_2$ ו- $y \in B$ אז גם $y' \in B$ כאשר $y = y'$ מלבד הקורדינטה הראשונה. לעומת זאת, המאורע $B = \{x \in \Omega \mid \exists m \forall n > m, x_n = 0\}$ מקיים $B \in \mathcal{T}_m$.

משפט 2.13 (חוק 0,1 של קולמוגורוב) אם $(\Omega, \mathcal{F}, \mathbb{P})$ מרחב הסתברות ו- $\mathcal{F}_n$ סדרת תת- σ -אלגברות בלתי-תלויה, ו- $A \in \mathcal{T}$ מאורע זנב, אז,

$$\mathbb{P}(A) \in \{0, 1\}$$

דוגמה 2.8 נבחן את הגרף $\mathbb{Z}^2$ עם צביעה אקראית בשני צבעים, ושאלנו בשיעור הקודם מה ההסתברות שיש רכיב קשירות אינסופי באחד הצבעים, עתה נטען שזהו מאורע זנב.

29.4.2026 – 3 שיעור 3

נמשיך לעסוק במשפט 2.13 ונראה דוגמה למקרה שהמשפט מייצג.

דוגמה 3.1 יהי $G = (V, E)$ גרף אינסופי קשיר עם דרגות סופיות, ונגדיר $\Omega = \{0, 1\}^E$ כמרחב מכפלה של צביעות, כאשר ההסתברות לצביעה היא $1 - p$ עבור 0 ו- p עבור 1 . עבור $w \in \Omega$ נגדיר $E' = \{e \in E \mid w_e = 1\}$ ונגדיר את תת-הגרף (V, E') . נסמן $F_e = \sigma(A_e)$ עבור $A_e = \{w \in \Omega \mid w_e = 1\}$ קיים ב- (V, E') רכיב קשירות אינסופי הוא מאורע זנב. נבחין כי $A \in T_n$ אם ורק אם x, y שונים רק ב- $n - 1$ הקורדינטות הראשונות אז או $x, y \in A$ או $x, y \notin A$ (תרגיל). $x, y \notin A$ נסיק שאם $f(0) = 0, f(1) = 1$ ולכן קיים $0 \leq p_c \leq 1$ נקודת אי-רציפות. אם $B^C = \bigcap_{v \in V} D_v$ ו- D_v המאורע ש- v נמצא ברכיב קשירות סופי אז נקבל ש- $D_v = \bigcup_{i \in \mathbb{N}} D_v^i$ וכן $B^C = \bigcap_{v \in V} D_v$ נטען ש- $\frac{1}{3} \leq p_c$ אם ורק אם לכל $p < \frac{1}{3}$ מתקיים $f(p) = 0$. יהי $p < \frac{1}{3}$, אז הסתברות המאורע שקיים מסלול אינסופי פשוט שמתחיל ב- v ונרצה למצוא את ההסתברות שקיים מסלול כזה באורך n .

טענה 3.1 תהי $\mathcal{F} = \sigma(\mathcal{F}_0)$ אלגברה ו- $\mathcal{F}_0$ אלגברה כך ש- $\mathcal{F} = \sigma(\mathcal{F}_0)$ לכל $A \in \mathcal{F}$ ולכל $\varepsilon > 0$ קיימת $A_0 \in \mathcal{F}_0$ כך ש- $0 \leq \mathbb{P}(A \Delta A_0) < \varepsilon$.

תרגיל 3.1 הוכיחו טענה זו.

יהי $A \in T$ ויהי $\varepsilon > 0$, אז,

$$A \in \sigma\left(\bigcup_{m \in \mathbb{N}} \sigma\left(\bigcup_{k=1}^m \mathcal{F}_k\right)\right)$$

לפי הטענה קיימת $A_0 \in \bigcup_{m \in \mathbb{N}} \sigma(\dots)$ כך ש- $\mathbb{P}(A \Delta A_0) < \varepsilon$ קיים m_0 כך ש- $A_0 \in \sigma(\bigcup_{k=1}^{m_0} \mathcal{F}_k)$ ו- $A \in T_{m_0}$ בהתאם. לכן $\mathbb{P}(A \cap A_0^c) < \varepsilon$ ו- $\mathbb{P}(A_0 \cap A^c) < \varepsilon$. נסמן $p = \mathbb{P}(A)$, $p_0 = \mathbb{P}(A_0)$ ולכן $p - \varepsilon \leq p_0 \leq p + \varepsilon$.

משפט 3.2 (אינווריאנטיות להזזה בהסתברות) תהי $\Omega = \{0, 1\}^{\mathbb{Z}}$ מידת מכפלה, $A \in \mathcal{F}$ מאורע אינווריאנטי, אם לכל $x \in A$, x אם ורק אם $S(x) \in A$ כאשר $S(x)$ הזזה של הסדרה. אם A אינווריאנטי אז $\mathbb{P}(A) \in \{0, 1\}$.

3.1 משתנים מקריים

אם $(\Omega, \mathcal{F}, \mathbb{P})$ מרחב הסתברות אז משתנה מקרי הוא פונקציה מדידה מ- Ω ל- $\mathbb{R}$. תנאי מספיק למדידות הפונקציה X הוא שלכל $t \in \mathbb{R}$ יתקיים $X^{-1}((-\infty, t)) \in \mathcal{F}$. אם X, Y משתנים מקריים אז (X, Y) פונקציה מדידה מ- Ω ל- $\mathbb{R}^2$, ואם $X_1, X_2, \dots$ סדרת משתנים מקריים אז גם $(X_1, X_2, \dots)$ פונקציה מדידה על $\mathbb{R}^{\mathbb{N}}$.

אם נחזור לדוגמה של קודם נוכל להגדיר את $(\Omega, \mathcal{F}, \mathbb{P})$ לפי הגרף $G = (V, E)$. נניח שלכל $e \in E$ יש משתנה מקרי X_e המקריים $\mathbb{P}(X^{-1}(\{0, 1\})) = 1$. נקבל כך ש- $\{x_e\}_{e \in E}$ יוצר וקטור מקרי מ- Ω ל- $\{0, 1\}^E$.

מסקנה 3.3 כל פונקציה רציפה היא מדידה (בורל), והרכבה משמרת מדידות, לכן נסיק שאם X, Y משתנים מקריים אז גם $X + Y, X \cdot Y$ משתנים מקריים. $\max(X, Y)$ וכן הלאה. אם $\{X_n\}_{n \in \mathbb{N}}$ סדרת משתנים מקריים אז גם $\sup_n X_n$ משתנה מקרי, שכן $X_n \leq t \iff \sup_n X_n \leq t$. נסיק שגם $\limsup_{n \rightarrow \infty} X_n$ פונקציה מדידה ולכן משתנה מקרי גם כן. לכן גם $\{w \in \Omega \mid \limsup_{n \rightarrow \infty} X_n = \liminf_{n \rightarrow \infty} X_n\}$ מדידה.

X משתנה מקרי אז ההתפלגות של X היא הדחיפה קדימה של $\mathbb{P}$ דרך X , $\mathbb{P}_X$. נגדיר את התוחלת על-ידי,

$$\mathbb{E}(X) = \int_{\Omega} X d\mathbb{P} = \int_{\mathbb{R}} x d\mathbb{P}_X(x)$$

ראינו גם מה קורה כשאנחנו מרכיבים פונקציה על X במקרה זה.

אם X, Y משתנים מקריים אז נאמר שהם בלתי-תלויים אם $\sigma(X), \sigma(Y)$ בלתי-תלויים, כאשר $\sigma(X) = \{X^{-1}(B) \mid B \in \mathcal{F}\}$. זה שקול ל- $\mathbb{P}_{(X,Y)} = \mathbb{P}_X \times \mathbb{P}_Y$, ואם הם בלתי-תלויים אז גם $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$.

נאמר ש- $X_1, \dots, X_n$ בלתי-תלויים בזוגות אם לכל $i \neq j$, X_i, X_j בלתי-תלויים. אם זה מתקיים אז גם $\text{Var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{Var}(X_i)$.

למה 3.4 אם $\{A_n\}$ בלתי-תלויים בזוגות ו- $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$ אז $\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = 1$.

הוכחה. נגדיר $X_n = \mathbb{1}_{A_n}$ בלתי-תלויים בזוגות ו- $Y_n = \sum_{i=1}^n X_i$. נראה שמתקיים,

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right)^C = \mathbb{P}(Y_n = 0) \rightarrow 0$$

מתקיים מצ'בישב,

$$\mathbb{P}(Y_n = 0) \leq \mathbb{P}(|Y_n - \mathbb{E}(Y_n)|) \leq \frac{\text{Var}(Y_n)}{(\mathbb{E}(Y_n))^2}$$

וכן,

$$\text{Var}(Y_n) = \sum_{i=1}^n \text{Var}(Y_i) = \sum_{i=1}^n p_i(1 - p_i) \leq \sum_{i=1}^n p_i = \mathbb{E}(Y_n)$$

ומשילוב שתי הטענות נקבל ש- $\mathbb{P}(Y_n = 0) \rightarrow 0$ לכן $\mathbb{P}((\bigcup_{i=m}^{\infty} A_i)^C) = 0$. □

תרגיל 3.2 נניח ש- $A_1, \dots, A_n$ מאורעות בלתי-תלויים בזוגות כך ש- $\mathbb{P}(A_i) = \frac{1}{2}$ לכל $i \leq n$. מה יכולה להיות $\mathbb{P}(\bigcap_{i=1}^n A_i)$?

4 שיעור 6.5.2026

4.1 התכנסות

בשיעור הקודם דיברנו על σ -אלגברות אי-תלות משתנים מקריים, בורל קנטלי השני בהנחת אי-תלות בזוגות. עתה נדבר על התכנסות.

הגדרה 4.1 (התכנסות כמעט תמיד) $X_n \xrightarrow{a.s.} X$ אם $\mathbb{P}(X_n \rightarrow X) = 1$.

הגדרה 4.2 (התכנסות בהסתברות) נסמן $X_n \xrightarrow{p} X$ אם $\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0$ לכל $\varepsilon > 0$.

במידה ראינו משפטי התכנסות על אינטגרלי לבג, ננסח תוצאות שלהם בניסוח הסתברותי.

משפט 4.3 (התכנסות תוחלת) $X_n \xrightarrow{a.s.} X$ אז,

1. קיים M כך ש- $|X_n| \leq M$ לכל n (כמעט-תמיד) גורר ש- $\mathbb{E}(X_n) \rightarrow \mathbb{E}(X)$

2. אם $0 \leq X_1 \leq \dots$ אז $\mathbb{E}(X_n) \rightarrow \mathbb{E}(X)$ (במובן הרחב גם)

3. אם קיים Y עם תוחלת סופית כך ש- $|X_n| \leq Y$ לכל n אז $\mathbb{E}(X_n) \rightarrow \mathbb{E}(X)$

טענה 4.4 אם $X_n \rightarrow X$ כמעט תמיד אז $X_n \rightarrow X$ בהסתברות.

הוכחה. נגדיר $A_n^\varepsilon = \{|X_n - X| \leq \varepsilon\}$ אז $X_n \xrightarrow{a.s.} X$ אם ורק אם,

$$\forall \varepsilon > 0, \mathbb{P}(\liminf_{n \rightarrow \infty} A_n^\varepsilon) = 1$$

לעומת זאת, $X_n \xrightarrow{p} X$ אם ורק אם $\mathbb{P}(A_n^\varepsilon) \rightarrow 1$ לכל $\varepsilon > 0$. מהלמה של פאטו נקבל ש- $1 = \mathbb{P}(\liminf A_n^\varepsilon) \leq \liminf \mathbb{P}(A_n^\varepsilon) \leq 1$

הכיוון ההפוך של הגרירה הזאת הוא לא נכון, נראה דוגמה נגדית.

דוגמה 4.1 נגדיר $X_n = \mathbb{1}_{A_n}$ עבור A_n בלתי-תלויים כך ש- $\mathbb{P}(A_n) = p_n$ כך ש- $p_n \rightarrow 0$ ו- $\sum_{n=1}^\infty p_n = \infty$ (לדוגמה $p_n = \frac{1}{n}$). אז $X_n \xrightarrow{p} 0$ אבל $X_n \not\xrightarrow{a.s.} 0$ מבורל קנטלי.

טענה 4.5 אם $X_n \xrightarrow{p} X$ אז קיימת תת-סדרה X_{n_k} המקיימת $X_{n_k} \xrightarrow{a.s.} X$.

הוכחה. נגדיר $B_n^\varepsilon = \{|X_n - X| > \varepsilon\}$ ונסמן $p_n = \mathbb{P}(B_n)$ אז $p_n \rightarrow 0$ לפי הגדרת התכנסות בהסתברות. נבחר תת-סדרה n_k כך ש- $\sum_{k=1}^\infty p_{n_k} < \infty$ ואז מבורל-קנטלי הראשון נקבל $|X_{n_k} - X| \leq \varepsilon$ החל ממקום מסוים ולכן,

$$X - \varepsilon \leq \liminf X_{n_k} \leq \limsup X_{n_k} \leq X + \varepsilon$$

זה נכון לכל $\varepsilon > 0$ ולכן יש שוויון, השאר נובע מטיעון אלכסון של סדרות.

הגדרה 4.6 (מטריקה על משתנים מקריים) עבור X, Y משתנים מקריים מעל $(\Omega, \mathcal{F}, \mathbb{P})$ נגדיר את,

$$d(X, Y) = \inf\{\varepsilon > 0 \mid \mathbb{P}(|X - Y| > \varepsilon) < \varepsilon\}$$

תרגיל 4.1 הראו כי זוהי אכן מטריקה, והיא מגדירה $X_n \xrightarrow{p} X$.

אין מרחב מטרי שבו התכנסות סדרת משתנים מקריים שקולה להתכנסות כמעט תמיד. ננסח טענה טופולוגית שלא נוכיח,

טענה 4.7 במרחב טופולוגי או מטרי $a_n \rightarrow a$ אם ורק אם לכל תת-סדרה n_k יש תת-תת-סדרה $a_{n_{k_i}} \rightarrow a$.

אם נבחן את X_n מהדוגמה אז $X_n \not\xrightarrow{a.s.} X$ אבל $X_n \xrightarrow{p} 0$ ולכן $X_{n_k} \xrightarrow{p} 0$ לכל תת-סדרה, ולפי הטענה שהוכחנו על תת-סדרות מתכנסות, נוכל לקחת תת-סדרה $X_{n_{k_i}} \xrightarrow{a.s.} 0$ ונקבל את המסקנה הבאה,

מסקנה 4.8 התכנסות כמעט תמיד איננה טופולוגית או מטרי.

4.2 החוק החזק והחלש של המספרים הגדולים

משפט 4.9 (החוק החזק של המספרים הגדולים) אם X_n משתנים מקריים שוויהתפלגות ובלתי-תלויים ובעלי תוחלת μ אז,

$$\frac{1}{n} S_n \xrightarrow{p} \mu$$

כאשר $S_n = \sum_{i=1}^n X_i$

הוכחה (תחת אי-תלות בזוגות). נניח שקיימת שונות למשתנים המקריים σ^2 ,

$$\text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) + \overbrace{\text{Cov}(\dots)}^{=0} = \frac{\sigma^2}{n} \rightarrow 0$$

בהתאם,

$$\mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| > \varepsilon\right) \leq \frac{\text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2 n}$$

מצ'בישב.

עתה נניח רק ש- $X_i \geq 0$. יהי $M > 0$ כלשהו, נגדיר $X'_i = X_i \mathbb{1}_{\{X_i \leq M\}}$ ו- $X''_i = X_i \mathbb{1}_{\{X_i > M\}}$ ולכן $X_i = X'_i + X''_i$. נקבל,

$$0 \leq X'_i \leq M$$

נסמן $\mathbb{E}(X'_i) = \mu'$, $\mathbb{E}(X''_i) = \mu''$ ולכן גם $\mu = \mu' + \mu''$, ונבחין כי נקבל של- X'_i שונות סופית $(\sigma'_i)^2$.

נראה שלכל $\varepsilon > 0$ קיים M כך ש- $\mathbb{E}(X''_i) \leq \varepsilon$. נבחן את הסדרה $X_1 \mathbb{1}_{\{X_1 \leq M\}}$ אז היא מתכנסת מונוטונית ל- X_i ולכן $\mu = \mathbb{E}(X_1 \mathbb{1}_{\{X_1 \leq M\}}) \rightarrow \mu$

אז $\mathbb{E}(X_1 \mathbb{1}_{\{X_1 > M\}}) \rightarrow 0$

נסמן $S'_n = \sum_{i=1}^n X'_i$ ואת S''_n באופן דומה, ויהי $\varepsilon > 0$,

$$\begin{aligned} \mathbb{P}\left(\left|\frac{1}{n} S_n - \mu\right| > \varepsilon\right) &= \mathbb{P}(|S_n - n\mu| > \varepsilon n) \\ &\leq \mathbb{P}(|S'_n - n\mu'| > \frac{\varepsilon}{2}n) + \mathbb{P}(|S''_n - n\mu''| > \frac{\varepsilon}{2}n) \\ &\stackrel{(1)}{\leq} \frac{(\sigma')^2}{(\frac{\varepsilon}{2})^2 n} + \frac{n\mu''}{\frac{\varepsilon}{2}n} \end{aligned}$$

כאשר (1) נובע מצ'בישב ומרקוב. נבחר M כך ש- $\mu'' \leq (\frac{\varepsilon}{2})^2$ ונקבל,

$$\frac{(\sigma')^2}{(\frac{\varepsilon}{2})^2 n} + \frac{\mu''}{\frac{\varepsilon}{2}} < \frac{\varepsilon}{2} + \frac{\varepsilon}{2}$$

בשלב האחרון נניח ש- X בעל תוחלת ונפרק $X_i^+ = X_i \mathbb{1}_{\{X_i \geq 0\}}$ וכן $X_i^- = X_i \mathbb{1}_{\{X_i \leq 0\}}$ ולכן $X_i = X_i^- + X_i^+$. בהתאם גם $\mu = \mu^- + \mu^+$.

בהתאם גם $\frac{1}{n} \sum_{i=1}^n X_i^+ \xrightarrow{p} \mu^+$ ואותו הדבר על μ^- . □

עתה נעבור לחוק החזק.

משפט 4.10 (החוק החזק של המספרים הגדולים) אם X_n משתנים מקריים שווי-התפלגות ובלתי-תלויים, אם הם בעלי תוחלת μ אז $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{a.s.} \mu$.

הוכחה. נניח תוחלת אפס בלי הגבלת הכלליות עליידי מעבר למשתנה מקרי ממורכז. נבחן את $A_{n^2}^\varepsilon$, אז $\sum_{n=1}^\infty \mathbb{P}(A_{n^2}^\varepsilon) < \infty$ ולכן,

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} A_{n^2}^\varepsilon\right) = 0 \iff \mathbb{P}(\liminf A_{n^2}^\varepsilon) = 1$$

אם $n^2 \leq k \leq (n+1)^2$,

$$\left| \sum_{i=n^2+1}^k X_i \right| = |S_k - S_{n^2}| \leq M \cdot 2n_k$$

ולכן,

$$\left| \frac{S_k}{k} - \frac{S_{n^2}}{n^2} \cdot \frac{n^2}{k} \right| \leq \frac{M2n_k}{k} \rightarrow 0$$

נראה שאם $X_i \geq 0$ שווי-התפלגות עם תוחלת μ ו- $\mathbb{P}(\limsup \frac{S_n}{n} \geq 4\mu) = 0$ יהי $k \in \mathbb{N}$ ונרצה לחסום את $\mathbb{P}(\frac{S_{2^k}}{2^k} > 2\mu)$. נגדיר,

$$X'_i = X_i \mathbb{1}_{\{X_i \leq 2^k\}}, \quad X''_i = X_i \mathbb{1}_{\{X_i > 2^k\}}$$

אז,

$$\mathbb{P}(S_{2^k} > 2\mu 2^k) \leq \mathbb{P}(S'_{2^k} > 2\mu 2^k) + \mathbb{P}(S''_{2^k} > 0)$$

נחסום אותם בנפרד,

$$\begin{aligned}\mathbb{P}(S'_{2^k} > 2\mu 2^k) &\leq \mathbb{P}(S'_{2^k} - 2^k \mu' > 2\mu 2^k - 2^k \mu') \\ &\leq \mathbb{P}(|S'_{2^k} - 2^k \mu'| \geq 2^k \mu) \\ &\stackrel{\text{צ'רישב}}{\leq} \frac{\text{Var}(S'_{2^k})}{2^{2k} \mu^2} \\ &= \frac{\text{Var}(X'_i)}{2^k \mu^2} \\ &\leq \frac{\mathbb{E}(X_1^2 \mathbb{1}_{\{X_1 \leq 2^k\}})}{2^k \mu^2}\end{aligned}$$

קיבלנו אם כך מאי-השוויון הקודם,

$$\begin{aligned}\mathbb{P}(S_{2^k} > 2\mu 2^k) &\leq \mathbb{P}(S'_{2^k} > 2\mu 2^k) + \mathbb{P}(S''_{2^k} > 0) \leq \frac{\mathbb{E}(X_1^2 \mathbb{1}_{\{X_1 \leq 2^k\}})}{2^k \mu^2} + 2^k \mathbb{P}(X_1 > 2^k) \\ \text{נסמן } p_0 &= \mathbb{P}(X_1 \leq 2) \text{ ונבור } k \in \mathbb{N} \text{ לכל } p_k = \mathbb{P}(2^k < X_1 \leq 2^{k+1}) \text{ בהתאם,} \\ \sum_{k=1}^{\infty} 2^k p_k &\leq 2\mu\end{aligned}$$

מתקיים,

$$\mathbb{P}(X_1 > 2^k) = \sum_{j=k}^{\infty} p_j, \quad \mathbb{E}(X_1^2 \mathbb{1}_{\{X_1 \leq 2^k\}}) \leq 4 \sum_{j=0}^{k-1} p_j 2^{2j}$$

וכן,

$$\sum_{k=1}^{\infty} \mathbb{P}(X_1 > 2^k) = \sum_{k=1}^{\infty} 2^k \sum_{j=k}^{\infty} p_j = \sum_{j=1}^{\infty} p_j \sum_{k=1}^j 2^k \leq 2 \sum_{j=1}^{\infty} p_j 2^{2j} \leq 4\mu < \infty$$

כלומר הטור סופי.

$$\sum_{k=1}^{\infty} \frac{1}{2^k} \sum_{j=0}^{k-1} p_j 2^{2j} = \sum_{j=0}^{\infty} p_j 2^{2j} \sum_{k=j}^{\infty} 2^{-k} = \sum_{j=0}^{\infty} p_j 2^{2j} \cdot 2^{-j} \cdot 2 = \sum_{j=0}^{\infty} p_j 2^j < \infty$$

אז במסתכם מצאנו ש- $\sum_{k=1}^{\infty} PP(\frac{1}{2^k} 2^{2k} > 2\mu) < \infty$, לכן מבורל-קנטלי הראשון נקבל שממקום מסוים,

$$\frac{S_{2^k}}{2^k} \leq 2\mu$$

נשים לב שאם $2^k < n \leq 2^{k+1}$ אז $S_{2^k} \leq S_n \leq S_{2^{k+1}}$ ולכן,

$$\frac{S_n}{n} \leq \frac{S_{2^{k+1}}}{n} = \frac{S_{2^{k+1}}}{2^{k+1}} \cdot \frac{2^{k+1}}{n} \leq 2 \cdot \frac{S_{2^{k+1}}}{2^{k+1}}$$

□

13.5.2026 – 5 שיעור 5

5.1 התכנסות – המשך

נעבור להוכחת המשפט החזק לאחר שסיימנו את הלמה הרלוונטית בשיעור הקודם.

הוכחה. נניח ש- $X_i \geq 0$ ויהי $\varepsilon > 0$, נבחר M מספיק גדול כך שאם,

$$X'_i = X_i \mathbb{1}_{\{X_i \leq M\}}, \quad X''_i = X_i \mathbb{1}_{\{X_i > M\}}$$

אז

$$\mathbb{E}(X'_i) > \mu - \varepsilon, \quad \mathbb{E}(X''_i) < \varepsilon$$

ונסמן,

$$S_n = S'_n + S''_n, \quad S'_n = \sum_{i=1}^n X'_i, \quad S''_n = \sum_{i=1}^n X''_i$$

ועתה נקבל,

$$\begin{aligned} \mu - \varepsilon &< \mathbb{E}(X'_1) \\ &= \lim_{n \rightarrow \infty} \frac{S'_n}{n} \\ &= \liminf_{n \rightarrow \infty} \frac{S'_n}{n} \\ &\leq \liminf_{n \rightarrow \infty} \frac{S_n}{n} \\ &\leq \limsup_{n \rightarrow \infty} \frac{S_n}{n} \\ &\leq \limsup_{n \rightarrow \infty} \frac{S'_n}{n} + \lim_{n \rightarrow \infty} \frac{S''_n}{n} \\ &\leq \mathbb{E}(X'_1) + 4\mathbb{E}(X''_1) \\ &\leq \mu + 4\varepsilon \end{aligned}$$

עבור X_i כלליים נפרק $X_i^+ = X_i \mathbb{1}_{\{X_i \geq 0\}}$ וכן $X_i^- = X_i \mathbb{1}_{\{X_i < 0\}}$ ואז $X_i = X_i^+ - X_i^-$.

אם $\frac{S_n}{n} \xrightarrow{\text{a.s.}} a$ אז $a = \mathbb{E}(X_i)$, מהצד השני אם ל- X_i אין תוחלת אז $\frac{S_n}{n}$ לא מתכנסת. אם $0 \leq X_i$ ו- $\mathbb{E}(X_i) = \infty$ אז $\frac{S_n}{n} \rightarrow \infty$ כמעט תמיד. קיימים משתנים מקריים X_i בלתי-תלויים ושווי התפלגות ללא תוחלת כך ש- $\frac{S_n}{n} \xrightarrow{P} a \in \mathbb{R}$.

5.2 פרדוקס המעטפות

נניח שאנו מקבלים שתי מעטפות, באחת יש a כסף ובשנייה $2a$, נקבל מעטפה אחת באקראי וראינו בה b , אז בשנייה יש או $2b$ או לחילופין $\frac{b}{2}$ כסף, ובהסתברות שווה.

בהתאם תוחלת המעטפה השנייה היא $\frac{5b}{4} > b$, כלומר לכאורה עלינו תמיד לבקש להחליף את המעטפה.

הפתרון הוא שאנחנו לא יכולים שלא להגדיר באופן ברור מהו a , גם לו יש התפלגות ואנו צריכים להתחשב בה. הפעם נסמן $X \geq 0$ סכום הכסף במעטפה ובהתאם $2X$ במעטפה השנייה, כאשר X משתנה מקרי, ונניח שהוא בדיד. נסמן את המדידה של המעטפה הראשונה Y . שתי האפשרויות בהתאם הן $Y = X$ או $Y = 2X$.

נניח ש- $\mathbb{P}(X = 1) = p_a > 0$. נרצה לבדוק אם יש התפלגות בדידה על X כך שנקבל תוצאה נכונה. אנו מניחים שמתקיים,

$$\mathbb{P}(Y = a) = \mathbb{P}(X = a) \frac{1}{2} + \mathbb{P}(X = \frac{a}{2}) \frac{1}{2}$$

ורוצים $\mathbb{P}(X = a | Y = a) = \frac{1}{2}$ נחשב,

$$\mathbb{P}(X = a | Y = a) = \frac{\mathbb{P}(X = a, Y = a)}{\mathbb{P}(Y = a)} = \frac{\mathbb{P}(X = a) \frac{1}{2}}{\mathbb{P}(X = a) \frac{1}{2} + \mathbb{P}(X = \frac{a}{2}) \frac{1}{2}} = \frac{p_a}{p_a + \frac{p_a}{2}} \Rightarrow p_{\frac{a}{2}} = p_a$$

וזו כמובן סתירה.

ענה נניח ש- $Z \sim \text{Geo}(\frac{1}{2})$, בהתאם,

$$\forall k \in \mathbb{N}, \mathbb{P}(Z = k) = 2^{-k}$$

ונניח ש- $X = 3^Z$ ונסה לחשב שוב את ההתפלגות של המעטפה השנייה. אם $Y = 3^k$ אז או ש- $X = 3^k$ או ש- $X = 3^{k-1}$. הפעם נקבל תוך הנחת $k > 1$,

$$\mathbb{P}(X = 3^k | Y = 3^k) = \frac{\mathbb{P}(X = 3^k) \frac{1}{2}}{\mathbb{P}(X = 3^k) \frac{1}{2} + \mathbb{P}(X = 3^{k-1}) \frac{1}{2}} = \frac{\mathbb{P}(Z = k)}{\mathbb{P}(Z = k) + \mathbb{P}(Z = k-1)} = \frac{2^{-k}}{2^{-k} + 2^{-(k-1)}} = \frac{1}{1+2} = \frac{1}{3}$$

כלומר,

$$\mathbb{P}(X = 3^k | Y = 3^k) = \begin{cases} \frac{1}{3} & k > 1 \\ 1 & k = 1 \end{cases}$$

לכן אם $k > 1$ אז $\mathbb{E}(\text{second envelope} | Y = 3^k) = \frac{1}{3} \cdot 3^{k+1} + \frac{2}{3} \cdot 3^{k-1} = 3^k \cdot \frac{11}{9}$. כלומר שוב קיבלנו שמשלם להחליף מעטפה, שוב באופן פרדוקסלי. הסיבה לפרדוקס היא שהתוחלת עצמה היא לא סופית, ולכן התוצאה לא משמעותית כפי שהיא נראית.

5.3 משפט הקירוב של ויירשטראס

ראינו בקורסים קודמים שהפולינומים צפופים ברציפות, נעסוק בנושא זה מזווית הסתברותית.

הגדרה 5.1 (פולינום ברנשטיין) אם $f \in C([0, 1])$ אז נגדיר,

$$B_n(x) = \sum_{k=0}^n f\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k}$$

נקרא פולינום ברנשטיין מסדר n של f .

הערה מתקיים $B_n(p) = \mathbb{E}(f(\frac{S_n}{n}))$ עבור $S_n \sim \text{Bin}(p, n)$.

טענה 5.2 $\|B_n - f\|_\infty \xrightarrow{n \rightarrow \infty} 0$.

הוכחה. f רציפה ולכן חסומה ונסמן $M < \infty$ חסם כלשהו, f גם רציפה במידה שווה. מרציפות במידה שווה לכל $\varepsilon > 0$,

$$\sup_{|x-y| < \varepsilon} |f(x) - f(y)| \rightarrow 0$$

וכן,

$$\begin{aligned} \forall p \in [0, 1], \|B_n(p) - f(p)\| &= |\mathbb{E}(f(\frac{S_n}{n}) - f(p))| \\ &\leq \mathbb{E}(|f(\frac{S_n}{n}) - f(p)|) \\ &\leq \mathbb{P}(|\frac{S_n}{n} - p| \geq \varepsilon) \cdot 2M + \mathbb{P}(|\frac{S_n}{n} - p| < \varepsilon) \cdot \mathbb{E}(|f(\frac{S_n}{n}) - f(p)|) \\ &\leq \frac{p(1-p)}{n\varepsilon^2} \cdot 2M + 1 \cdot M(\varepsilon) \\ &\xrightarrow[\varepsilon = \frac{1}{\sqrt{n}}]{n \rightarrow \infty} 0 \end{aligned}$$

□

5.4 הימורים

נסמן $p > \frac{1}{2}$ ונהמר $a > 0$ בהסתברות p , נפסיד a בהסתברות $1-p$. נקבל $Y_i \sim \text{Ber}(p)$ בלתי תלויים. נגדיר את $X_n = X_{n-1} + a_n(2Y_n - 1)$ וכן $X_0 = 1$ ולכן,

$$\mathbb{E}(X_1) = \mathbb{E}(X_0) + a(2p - 1), \quad \mathbb{E}(X_2) = \mathbb{E}(X_1) + a_2(2p - 1)$$

מתקיים,

$$\frac{1}{n} \sum_{i=1}^n \log X_i - \log X_{i-1} = \frac{1}{n} \log X_n = \log \sqrt[n]{X_n}$$

ולכן במקרה שלנו,

$$f_p(a) = p \log(1+a) + (1-p) \log(1-a), \quad f'_p(a) = \frac{p}{1+a} - \frac{1-p}{1-a}, \quad f'_p(a) = 0 \iff p(1-a) = (1-p)(1+a)$$

ולכן $a = 2p - 1$, כלומר מצאנו שלא משתלם להשקיע או להמר בכל פעם את כל כספנו, אלא משתלם להשקיע מספר מסוים וחלקי של הכסף.

5.5 אי-תלות בזוגות

נניח ש- $X_i \sim U(\{-1, 1\})$ עבור $i \in [n]$ בלתי-תלויים בזוגות, ונבדוק את,

$$\mathbb{P}\left(\sum_{i=1}^n X_i = n\right) \leq \mathbb{P}\left(\left|\sum_{i=1}^n X_i\right| \geq n\right) \leq \frac{\text{Var} \sum_{i=1}^n X_i}{n^2} = \frac{1}{n}$$

נרצה להבין אם זהו החסם הטוב ביותר לערך זה.

טענה 5.3 נגדיר $Y_i \sim U(\{-1, 1\})$ בלתי-תלויים עבור $i \in [k]$ ונגדיר לכל $\emptyset \neq I \subseteq [k]$ את,

$$X_I = \prod_{i \in I} Y_i$$

אז $X_I \sim U(\{-1, 1\})$ והם בלתי-תלויים בזוגות.

הוכחה. לחלק הראשון מספיק להראות ש- $\mathbb{E}(X_I) = 0$, אבל,

$$\mathbb{E}(X_I) = \mathbb{E}\left(\prod_{i \in I} Y_i\right) = \prod_{i \in I} \mathbb{E}(Y_i) = \prod_{i \in I} 0 = 0$$

נראה שהם בלתי-תלויים בזוגות, יהיו $I \neq J$ לא ריקות, אז,

$$X_I \cdot X_J = X_{I \Delta J}$$

ולכן,

$$\mathbb{E}(X_I X_J) = 0$$

אם $Z_1, Z_2 \sim U(\{-1, 1\})$ הם בלתי-מתואמים ($\mathbb{E}(Z_1 Z_2) = 0$) אז הם בלתי-תלויים (תרגיל). □

אתה נשאל מה ערך,

$$\mathbb{P}(\forall \emptyset \neq I \subseteq [k] X_I = 1) = \mathbb{P}(\forall i \in [k] Y_i = 1) = \frac{1}{2^k} = \frac{1}{n+1}$$

כלומר מצאנו חסם יותר טוב באופן זניח לשאלה המקורית שלנו.

20.5.2026 – 6 שיעור 6

6.1 שרשרות מרקוב

נתחיל מתיאור של מצב. נניח שצפרדע עומדת על פרח ויכולה לעבור לפרח אחר לחזור וכן הלאה. ההסתברות לעבור מפרח א' לפרח ב' היא q וההסתברות לעבור מפרח ב' לפרח א' היא p , ואנו רוצים להבין מה הסיכוי שתהיה בפרח מסוים לאורך זמן. נקבל בהתאם שאם X_n משתנה מקרי המתאר את מיקום הצפרדע באיטרציה ה- n אז מתקיים,

$$\mathbb{P}(X_{n+1} = W \mid X_t = E, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) = p \quad \mathbb{P}(X_{n+1} = E \mid X_t = W, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) = q$$

ניזכר שאם A, B, C מאורעות כך ש- $A \cap B = \emptyset$ ו- $\mathbb{P}(C \mid A) = \mathbb{P}(C \mid B) = p$ אז $\mathbb{P}(C \mid A \cup B) = p$. נקבל אם כך שמתקיים,

$$\mathbb{P}(X_{n+1} = W \mid X_n = E) = p, \quad \mathbb{P}(X_{n+1} = E \mid X_n = W) = q$$

בדיוק, כלומר אנו לא תלויים במה שקרה לפני האיטרציה האחרונה. נסמן $\mu_n(E) = \mathbb{P}(X_n = E)$, $\mu_n(W) = \mathbb{P}(X_n = W)$ ולכן,

$$\begin{aligned} \mu_{n+1}(E) &= \mathbb{P}(X_{n+1} = E) \\ &= \mathbb{P}(X_{n+1} = E \mid X_n = W) \mathbb{P}(X_n = W) + \mathbb{P}(X_{n+1} = E \mid X_n = E) \mathbb{P}(X_n = E) \\ &= q\mu_n(W) + (1-p)\mu_n(E) \end{aligned}$$

ולכן גם $\mu_{n+1}(W) = (1-q)\mu_n(W) + p\mu_n(E)$ אם נגדיר,

$$P = \begin{pmatrix} 1-p & p \\ q & 1-q \end{pmatrix}$$

נקבל שמתקיים $\mu_{n+1} = \mu_n \cdot P$ ולכן גם $\mu_n = \mu_0 P^n$ לכל $n \in \mathbb{N}$. אם נקבל התכנסות על $n \rightarrow \infty$ אז קיים $\mu = (r, 1-r)$ כך שמתקיים $\mu = \mu P$ ולכן נובע ש- $r = (1-p)r + q(1-r)$ ולכן $r = \frac{q}{p+q}$. בהתאם $\mu = (\frac{q}{p+q}, \frac{p}{p+q})$. עתה נניח ש- $\mu_n \rightarrow \mu$ ולכן,

$$\Delta_{n+1} = \mu_{n+1}(E) - \frac{q}{p+q} = (1-p)\mu_n(E) + q(1-\mu_n(E)) - \frac{q}{p+q} = q + (1-p-q)(\mu_n(E) - \frac{q}{p+q})$$

ונובע,

$$\Delta_{n+1} = (1-p-q)\Delta_n$$

ולכן גם,

$$\Delta_n = (1-p-q)\Delta_0$$

$X_0, X_1, \dots$ המשתנים המקריים שמקבלים ערכים ב- S קבוצת המצבים עבור S בדידה עם טופולוגיה σ -אלגברה בדידה.

הגדרה 6.1 (שרשרת מרקוב) $X_0, X_1, \dots$ היא שרשרת מרקוב עם מטריצת מעבר $P \in M_{S \times S}$ אם,

$$\mathbb{P}(X_{t+1} = s_{t+1} \mid X_t = s_t, X_{t-1} = s_{t-1}, \dots, X_0 = s_0) = P_{s_{t+1}, s_t}$$

לכל t ולכל $s_0, \dots, s_{t+1} \in S$

למעשה,

$$P(s_{t+1}, s_t) = \mathbb{P}(X_{t+1} = s_{t+1} \mid X_t = s_t)$$

בלבד מאותה הסיבה של קודם. התפלגות על S היא וקטור עם ערכים אי-שליליים שסכומם 1, ו- Δ_S נקרא סימפלקס קבוצת כל ההתפלגויות על S .

הגדרה 6.2 (סטציונריות) $\mu \in \Delta_S$ נקראת סטציונרית אם $\mu = \mu P$.

טענה 6.3 אם S סופית אז קיימת התפלגות סטציונרית.

הוכחה. ניקח $\mu_0 \in \Delta_S$ כלשהי ונגדיר $\mu_t = \mu_0 P^t$, נגדיר,

$$\Delta_S \ni \nu_t = \frac{1}{t} \sum_{i=1}^t \mu_i$$

אבל Δ_S קומפקטית ולכן יש תת-סדרה מתכנסת $\nu \rightarrow \nu_{t_k}$, נרצה להראות ש- ν היא סטציונרית.

$$\nu_t P = \frac{1}{t} \sum_{i=1}^y \mu_i P = \frac{1}{t} \sum_{i=2}^{t+1} \mu_i$$

ונקבל,

$$\nu(P - I) = \nu_t P - \nu_t = \frac{1}{t}(\nu_{t+1} - \nu_t)$$

ולכן $\nu(P - I) \rightarrow 0$ ובפרט $\nu_{t_k}(P - I) \rightarrow 0$ ולכן $\nu(P - I) = \nu P - \nu$.

דוגמה 6.1 יהי $G = (V, E)$ גרף פשוט לא מכוון עם דרגות סופיות. מטריצת המעבר של הילוך מקרי פשוט על G היא,

$$P(u, v) = \begin{cases} \frac{1}{\deg u} & u \sim v \\ 0 & \text{otherwise} \end{cases}$$

טענה 6.4 המידה $\mu(v) = \deg v$ היא סטציונרית, $\mu = \mu P$.

הוכחה.

$$(\mu P)(v) = \sum_{u \in V} \mu(u) P(u, v) = \sum_{u \sim v} \deg(u) \cdot \frac{1}{\deg u} = \deg v = \mu(v)$$

אם G סופי אז אפשר לנרמל ולקבל התפלגות ב- Δ_V , אם G אינסופי אז זה לא עובד.

נרחיב עתה את הדוגמה ונניח ש- G בעל משקולות, כלומר קיימת $C : E \rightarrow \mathbb{R}^+$ ונגדיר,

$$\pi(u) = \sum_{u \sim v} C_{uv}$$

ונגדיר,

$$P(u, v) = \frac{C_{uv}}{\pi(u)}$$

טענה 6.5 זוהי מטריצה מקרית ו- π היא סטציונרית, כלומר $\pi = \pi P$.

27.5.2026 – 7 שיעור 7

7.1 שרשרות מרקוב

נמשיך את הדיון על שרשרות בהתאם להגדרה שסיפקנו בהרצאה הקודמת. נניח ש- $X_0, \dots$ סדרת משתנים מקריים שמקבלים ערכים בקבוצה S הבדידה. הגדרנו גם את $P \in M_{S \times S}$ כך שלכל $s_0, \dots, s_1 \in S$ מתקיים,

$$\mathbb{P}(X_{n+1} = s_{n+1} \mid \forall i \leq n, X_i = s_i) = P(s_n, s_{n+1})$$

ולכן בפרט גם המטריצה היא סטוכסטית, כלומר $\sum_{y \in S} P(x, y) = 1 \forall x$. גם הראינו שאם $\mu_0 \in \Delta_S$ ו- $\mu_0 \sim X_0$ אז $\mu_n = \mu_0 P^n$.
הוכחנו שלכל P סטוכסטית קיימת $\pi \in \Delta_S$ כך ש- $\pi P = \pi$ (סטציונרית) על S סופית.
עתה נרצה להראות שמתקיים,

$$\mathbb{P}_s(X_n = t) = P^n(s, t)$$

$$\mathbb{P}_s(X_{n+1} = t) = \sum_{r \in S} \mathbb{P}_s(X_n = r) \mathbb{P}_s(X_{n+1} = t \mid X_n = r) = \sum_{r \in S} P^n(s, r) P(r, t) = (P^n \cdot P)(s, t) = P^{n+1}(s, t)$$

הגדרה 7.1 (איברים ניתנים להגעה) בהינתן P נאמר שאפשר להגיע מ- x ל- y עבור $x, y \in S$ אם קיים n כך ש- $P^n(x, y) > 0$.

הגדרה 7.2 (שרשרת אי-פריקה) שרשרת נקראת אי-פריקה אם אפשר להגיע מכל מצב לכל מצב

משפט 7.3 (יחידות התפלגות אי-פריקה) אם P אי-פריקה ו- S סופית אז ההתפלגות הסטציונרית היא יחידה.

הוכחה. נראה שאם P אי-פריקה אז מימד המרחב העצמי של 1 הוא 1. נסמן את $h = (1, \dots, 1)$ וקטור עצמי כזה, כלומר $h = Ph$. בהתאם,

$$h(x) = \sum_y P(x, y) h(y) = \mathbb{E}_x(h(X_1))$$

נגדיר $M = \max_{x \in S} h(x)$ ונסמן x_0 כך ש- $h(x_0) = M$, אז,

$$M = h(x_0) = \sum_u P(x_0, u) h(u) \leq \sum_y P(x_0, y) M = M$$

ולכן $P(x_0, y) = P(x_0, y) M$ לכל y . נובע שלכל y עבורו $0 < P(x_0, y)$ מתקיים $P(y) = M$.
 P אי-פריקה ולכן אפשר להגיע מכל x לכל y ונובע ש- $h \equiv M$.
□

אנו יודעים ש- $\pi P = \pi$ ולכן ממשפט זה נסיק שהוא היחיד במקרה זה.

תהי P שרשרת-מרקוב על S סופית, עבור x נסמן,

$$\mathbb{N} \supseteq A_x = \{n > 0 \mid P^n(x, x) > 0\}$$

ונסמן $a_x = \gcd A_x$ להיות המחזור של x .

A_x סגורה לחיבור כי $P^n P^m = P^{n+m}$ ולכן אם $0 < P^n(x, x)$ וגם $0 < P^m(x, x)$ אז גם $0 < P^{n+m}(x, x)$.

טענה 7.4 אם $A \subseteq \mathbb{N}$ סגורה לחיבור אז $|\gcd(A) \setminus A| < \infty$.

טענה 7.5 אם P אי-פריקה אז כל ה- a_x שווים.

הוכחה. יהיו $x, y \in S$ ונרצה להראות ש- $a_x = a_y$.

יש n כך ש- $P^n(x, y) > 0$ ויש m כך ש- $P^m(y, x) > 0$. אם $k \in A_x$ אז $m + n + k \in A_y$ כי,

$$P^{n+m+k}(y, y) = P^m(y, x) P^k(x, x) P^n(x, y) > 0$$

לכן $\gcd(A_y) \leq \gcd(A_x)$ ומסימטריה $a_y = a_x$.
□

מסקנה 7.6 אם P אי-פריקה אז $a_x = a$ $\forall x$, לאיזשהו $a \in \mathbb{N}$, נקרא לו המחזור של P .

משפט 7.7 אם P אי-פריקה על S סופית ולא מחזורית (כלומר $a = 1$) אז לכל $\mu_0 \in \Delta_S$ מתקיים $\mu_n = \mu_0 P^n \rightarrow \pi$ עבור π המידה הסטציונרית היחידה.

הוכחה. נניח ש- $P(x, y) > 0$ לכל x, y . במקרה זה קיים $\varepsilon > 0$ כך שלכל $x, y \in S$ מתקיים $P(x, y) \geq \varepsilon \pi(y)$. לכן אם $\mu_0 \in \Delta_S$ ונסמן $\mu_0 = \nu_0$ אז קיים $\nu_1 \in \Delta_S$ כך שמתקיים,

$$\nu_0 P = \varepsilon \pi + (1 - \varepsilon) \nu_1$$

ולכן קיים גם ν_2 כך שגם,

$$\nu_1 P = \mu_1 P = \varepsilon \pi + (1 - \varepsilon) \nu_2$$

ונמשיך ככה לקבל סדרה,

$$\nu_n P = \varepsilon \pi + (1 - \varepsilon) \nu_{n+1}$$

נקבל,

$$\mu_n = (1 - (1 - \varepsilon)^n) \pi + (1 - \varepsilon)^n \nu_n$$

ולכן,

$$\begin{aligned} \mu_{n+1} &= \mu P \\ &= (1 - (1 - \varepsilon)^n) \pi + (1 - \varepsilon)^n \nu_n P \\ &= (1 - (1 - \varepsilon)^n) \pi + (1 - \varepsilon)^n (\varepsilon \pi + (1 - \varepsilon) \nu_{n+1}) \\ &= (1 - (1 - \varepsilon)^n - (1 - \varepsilon)^n \varepsilon) \pi + (1 - \varepsilon)^{n+1} \nu_{n+1} \end{aligned}$$

עתה נניח ש- P לא מחזורית ולכן קיים $n \in \mathbb{N}$ כך ש- $P^n(x, y) > 0$ $\forall x, y \in S$, כי מאי־פריקות קיים n כך ש- $P^n(x, y) > 0$ ומהטענה הקודמת מתקיים $0 < P^n(x, x)$ עבור כל n גדול מספיק. לכן,

$$P^{n+m}(x, y) \geq P^n(x, x) P^m(x, y) > 0$$

ונובע ש- $P^r(x, y) > 0$ לכל x, y לאיזשהו $r \in \mathbb{N}$. מתקיים $\pi = \pi P^r$ ולפי המקרה הקודם לשרשרת P^r נקבל $\mu P^{rn} \rightarrow \pi$ ובאופן דומה גם $\mu P^{rn+k} = (\mu P^k) P^{rn} \rightarrow \pi$ לכל $0 \leq k < r$. $\square$

הגדרה 7.8 (גרף קיילי) אם G חבורה ו- $B \subseteq G$ סימטרית, כלומר $b \in B \implies b^{-1} \in B$. נגדיר גרף קיילי עם קבוצת יוצרים B עם הקשר $x \sim y \iff xy^{-1} \in B$ אם G סופית אז התפלגות אחידה היא סטציונרית.

8 שיעור 8 — 3.6.2026

8.1 שרשרות מרקוב

נניח שוב ש- S סופית ו- $\Delta_S \subseteq \mathbb{R}^S$, $\mu, \pi \in \Delta_S$, כאשר,

$$\Delta_S = \{x \in \mathbb{R}^S \mid \sum_{s \in S} x_s = 1, x_s \geq 0\}$$

טענה 8.1 יהיו $\mu, \nu \in \Delta_S$,

$$\max_{f: S \rightarrow [0,1]} \mathbb{E}(f(X)) - \mathbb{E}(f(Y)) \|\mu - \nu\|_1 = \sum_{s \in S} |\mu(s) - \nu(s)|$$

כאשר $\nu \sim Y, \mu \sim X$.

הוכחה. מהגדרת התוחלת,

$$\mathbb{E}(f(X)) - \mathbb{E}(f(Y)) = \sum_{s \in S} f(s)(\mu(s) - \nu(s)) \leq \sum_{s \in S} 1 \cdot |\mu(s) - \nu(s)| = \|\mu - \nu\|_1$$

□

8.2 צימודים

הגדרה 8.2 (צימוד) תהינה $\mu, \nu \in \Delta_S$, אז הצימוד של μ ו- ν הוא זוג משתנים מקריים (X, Y) שמקבלים ערכים ב- S , כך $\nu \sim Y, \mu \sim X$, כלומר,

$$\mathbb{P}(X = s) = \mu(s), \quad \mathbb{P}(Y = s) = \nu(s)$$

טענה 8.3 אם (X, Y) הוא צימוד של (μ, ν) , אז,

$$\|\mu - \nu\|_1 \leq \mathbb{P}(X \neq Y)$$

הוכחה. תהי $f: S \rightarrow [-1, 1]$, אז,

$$\begin{aligned} \mathbb{E}(f(X)) - \mathbb{E}(f(Y)) &= \mathbb{E}(f(X) - f(Y)) \\ &= \mathbb{E}(f(X) - f(Y) \mid X = Y) \mathbb{P}(X = Y) + \mathbb{E}(f(X) - f(Y) \mid X \neq Y) \mathbb{P}(X \neq Y) \\ &\leq 2 \mathbb{P}(X \neq Y) \end{aligned}$$

□

נרצה צימוד של μ_n ו- $\nu_n = \pi$ (אם $\nu_0 = \pi$), הצימוד: מגרילים את $X_0 \sim \mu_0$ ואת $Y_0 \sim \nu_0 = \pi$ באופן בלתי-תלוי. נגדיר שרשרת מרקוב על $S \times S$ עם הסתברויות מעבר,

$$\mathbb{P}((X_{n+1}, Y_{n+1}) = (x_{n+1}, y_{n+1}) \mid \forall i \leq n, (X_i, Y_i) = (x_i, y_i)) = \begin{cases} P(x_n, x_{n+1}) \cdot P(y_n, y_{n+1}) & x_n \neq y_n \\ P(x_n, x_{n+1}) & x_n = y_n, x_{n+1} = y_{n+1} \\ 0 & \text{אחרת} \end{cases}$$

בהגדרה זו X_n היא שרשרת מרקוב עם הסתברות P וכך גם Y_n ובפרט (X_n, Y_n) היא צימוד של (μ_n, ν_n) . נסמן $A_n = \{X_n \neq Y_n\}$ ונשים לב שזו סדרה יורדת. נניח ש- $0 < P(s, s') \leq a < 1$ לכל $s, s' \in S$ ואז קיים $a > 0$ כך ש- $P(s, s') \geq a$ ולכן $1 - a \leq \mathbb{P}(A_{n+1} \mid A_n)$.

$$\mathbb{P}(X_{n+1} = Y_{n+1} \mid \forall i \leq n, X_i = x_i, Y_i = y_i) \geq \sum_{s \in S} P(x_n, s) P(y_n, s) \geq |S| a^2 > 0$$

ולכן $\mathbb{P}(A_n) \leq (1 - |S| a^2)^n$.

8.3 פילטרציה

הגדרה 8.4 (פילטרציה) יהי $(\Omega, \mathcal{F})$ מרחב מדיד. פילטרציה היא סדרה עולה של תת- σ -אלגברות של $\mathcal{F}$, $\{\mathcal{F}_n\}_{n \in \mathbb{N}}$.

הגדרה 8.5 (הפילטרציה הטבעית) אם $\{X_n\}_{n \in \mathbb{N}}$ תהליך מקרי ונסמן,

$$\mathcal{F}_n = \sigma(X_0, \dots, X_n)$$

נגדיר את $\{\mathcal{F}_n\}$ להיות הפילטרציה הטבעית של $\{X_n\}$.

הגדרה 8.6 (זמן עצירה) אם $(\Omega, \mathcal{F})$ מרחב מדיד ו- $\{\mathcal{F}_n\}_{n \in \mathbb{N}}$ פילטרציה אז $\tau : \Omega \rightarrow \mathbb{N}$ נקרא זמן עצירה ביחס לפילטרציה $\{\mathcal{F}_n\}$ אם לכל $n \in \mathbb{N}$ מתקיים,

$$\{\tau = n\} \in \mathcal{F}_n$$

באופן שקול אם $\{\tau \leq n\} \in \mathcal{F}_n$.

המטרה שלנו היא להסתכל על זה כפונקציה שמתארת תנאי עצירה של סדרת פעולות, בהתאם היא צריכה להיות מדידה אחורנית בלבד. לדוגמה הטלת מטבע עד שצד א' יצא.

דוגמה 8.1 נגדיר X_i סדרת משתנים מקריים ונגדיר,

$$\tau = \min\{n \in \mathbb{N} \mid X_n = 1\}$$

אז $\tau \leq n$ אם ורק אם $\exists i \leq n, X_i = 1$.

הגדרה 8.7 (מאורעות שנגמרים אחרי זמן סופי) אם τ זמן עצירה, אז נגדיר,

$$\mathcal{F}_\tau = \{A \in \mathcal{F} \mid \forall n \in \mathbb{N}, A \cap \{\tau \leq n\} \in \mathcal{F}_n\}$$

משפט 8.8 (תכונת מרקוב החזקה) תהי $\{X_n\}_{n \in \mathbb{N}}$ שרשרת מרקוב על S עם מטריצת מעבר P . עבור $s \in S$ ו- τ זמן עצירה ביחס לפילטרציה הטבעית נגדיר $Y_n = X_{\tau+n}$ לכל $n \in \mathbb{N}$ (אם $\tau = \infty$ אז נגדיר את Y_n שרירותית).

בהינתן $\tau < \infty$ ו- $X_\tau = s$ אז $\{\tau_n\}_{n \in \mathbb{N}}$ היא שרשרת מרקוב שמתחילה ב- s עם מטריצת מעבר P והיא בלתי-תלויה ב- $\mathcal{F}_\tau$.

הוכחה. תהי $x_0, \dots, x_n \in S$ כך ש- $x_n = s$ ו- $\tau = n$ ו- $A = \{(X_1, \dots, X_n) = (x_1, \dots, x_n)\} \subseteq \{\tau = n\}$ לכן $A \subseteq \{X_\tau = s\}$. תהי גם $B = \{(Y_0, \dots, Y_m) = (y_0, \dots, y_m)\}$ ונסמן $y_0 = s$ כך ש- $y_0 = s$.

$$\begin{aligned} \mathbb{P}(A \cap B \mid \tau < \infty, X_\tau = s) &= \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(\tau < \infty, X_\tau = s)} \\ &= \frac{\mathbb{P}((X_0, \dots, X_{n+m}) = (x_0, \dots, x_n, y_1, \dots, y_m))}{\mathbb{P}(\tau < \infty, X_\tau = s)} \\ &= \frac{\mu_0(x_0) \prod_{i=1}^{n-1} P(x_i, x_{i+1}) \prod_{j=0}^{m-1} P(y_j, y_{j+1})}{\mathbb{P}(\tau < \infty, X_\tau = s)} \\ &= \frac{\mathbb{P}(A)}{\mathbb{P}(\tau < \infty, X_\tau = s)} \cdot \mathbb{P}(B) \end{aligned}$$

□

10.6.2026 – 9 שיעור 9

9.1 מרטינגלים

נתחיל מהגדרה שאיננה הכללית, ולאחריה נמשיך ולבסוף נרחיב אותה.

הגדרה 9.1 (מרטינגל) סדרת משתנים מקריים בדידים $\{X_n\}_{n \in \mathbb{N}}$ נקראת **מרטינגל** אם,

$$\mathbb{E}(X_{n+1} \mid X_0 = x_0, \dots, X_n = x_n) = x_n$$

לכל $n \in \mathbb{N}$ ולכל $x_0, \dots, x_n \in \mathbb{R}$ בתומך של $(X_0, \dots, X_n)$.

הרעיון הוא שאם נעשה סדרת הימורים (כאשר המשתנה המקרי במקום ה- n מייצג את סכום הכסף לאחר ההימור ה- n) אז ההימור הוא הוגן ביחס לקודמיו, ובתוחלת לא נפסיד ולא נרוויח כסף.

דוגמה 9.1 אם $\{X_n\}_{n=1}^\infty$ משתנים מקריים בדידים בלתי תלויים עם $\mathbb{E}(X_n) = 0$, ונגדיר $Y_n = \sum_{i=1}^n X_i$ אז Y_n הוא מרטינגל, נבדוק זאת,

$$\mathbb{E}(Y_{n+1} \mid Y_0 = y_0, \dots, Y_n = y_n) = \mathbb{E}(Y_n + X_{n+1} \mid \dots)$$

$$= \mathbb{E}(y_n + X_{n+1} \mid \dots) = y_n + \mathbb{E}(X_{n+1} \mid \dots) = y_n + \mathbb{E}(X_{n+1}) = y_n$$

כאשר המהלך האחרון נובע ישירות מאי תלות שהנחנו של X_{n+1} .

דוגמה 9.2 נניח ש- X_n שרשרת מרקוב על S עם מטריצת מעבר P ונניח ש- $h : S \rightarrow \mathbb{R}$ היא הרמונית, כלומר,

$$h = Ph \iff \forall x \in S, h(x) = \sum_{y \in S} P(x, y)h(y)$$

אז $h(X_n)$ הוא מרטינגל.

הוכחה. נסמן $Y_n = h(X_n)$ ואת המאורע $A = (Y_0, \dots, Y_n) = (y_0, \dots, y_n)$ ולכן,

$$\mathbb{E}(Y_{n+1} \mid A) = \mathbb{E}(h(X_{n+1}) \mid A)$$

$$= \sum_{x_0, \dots, x_n \in S} \mathbb{P}(X_0, \dots, X_n = x_0, \dots, x_n) \mathbb{E}(h(X_{n+1}) \mid A, (X_0, \dots, X_n) = (x_0, \dots, x_n))$$

כאשר נבחין כי $x_0, \dots, x_n$ תלויים ב- A , כלומר לא כל בחירה מניבה ערך חיובי.

$$\mathbb{E}(h(X_{n+1}) \mid (X_0, \dots, X_n) = (x_0, \dots, x_n)) = \sum_y P(x_n, y)h(y) = Ph(x_n) = h(x_n) = y_n$$

מתכונת מרקוב, ובהתאם סיימנו משילוב שני השוויונות. □

דוגמה 9.3 נגדיר את $h(x, y) = x^2 - y^2$, כפונקציה $\mathbb{R}^2 \rightarrow \mathbb{R}$ נקבל שהיא הרמונית במובן של אנליזה. במובן שלנו כפונקציה $\mathbb{R} \rightarrow \mathbb{R}$ על שרשרת מרקוב $\mathbb{Z}^2$ נרצה להראות,

$$h(x, y) = \frac{1}{4}(h(x+1, y+1) + h(x+1, y-1) + h(x-1, y+1) + h(x-1, y-1))$$

על ידי חישוב ישיר נקבל שתנאי זה אכן מתקיים ולכן h הרמונית גם במובן שלנו.

דוגמה 9.4 (הכד של פוליה) מתחילים עם כד אחד שחור ואחד לבן בכד, ובכל פעם שולפים כדור כדור באקראי, מסתכלים על הצבע שלו ואז מחזירים אותו לכד יחד עם כדור חדש באותו הצבע.

נתחיל בזמן 2 כדי שיהיו מספר כדורים כמספר הזמן, ונסמן X_n מספר הכדורים השחורים, בהתאם $X_n - n$ הוא מספר הכדורים הלבנים בזמן n .

טענה 9.2 $\frac{X_n}{n}$ הוא מרטינגל.

הוכחה. תרגיל. □

עתה נעבור לגרסה הכללית יותר של מרטינגל, אפילו שלא נשתמש בה רבות.

9.2 תוחלת מותנית

נניח ש- $(\Omega, \mathcal{F}, \mathbb{P})$ מרחב הסתברות ותהי $\mathcal{G} \subseteq \mathcal{F}$ תת-אלגברה, ונניח ש- X משתנה מקרי בעל תוחלת.

הגדרה 9.3 (תוחלת מותנית) נאמר ש- Y הוא התוחלת המותנית של X בהינתן $\mathcal{G}$ ונסמן $Y = \mathbb{E}[X | \mathcal{G}]$ אם מתקיימים התנאים הבאים:

1. Y הוא $\mathcal{G}$ -מדיד

2. לכל $A \in \mathcal{G}$ מתקיים $\mathbb{E}(X \mathbb{1}_A) = \mathbb{E}(Y \mathbb{1}_A)$, או באופן שקול $\mathbb{E}(X | A) = \mathbb{E}(Y | A)$ לכל A מאורע מהסתברות חיובית.

נבחין כי Y הוא משתנה מקרי, תוחלת מותנית איננה ערך סקלרי.

דוגמה 9.5 נסמן $\mathcal{G} = \{\emptyset, \Omega, A, A^C\}$ עבור מאורע $0 < \mathbb{P}(A) < 1$ כלשהו. אז $Y : \Omega \rightarrow \mathbb{R}$ צריך להיות $\mathcal{G}$ -מדיד ולכן $Y|_A \equiv a$ ו- $Y|_{A^C} \equiv b$ ומחישוב נקבל,

$$a = \mathbb{E}(X | A) = \frac{\mathbb{E}(\mathbb{1}_A)}{\mathbb{P}(A)}, \quad b = \mathbb{E}(X | A^C) = \frac{\mathbb{E}(\mathbb{1}_{A^C})}{1 - \mathbb{P}(A)}$$

נותר לנו להראות שקיימת תוחלת מותנית במובן החדש, כלומר עבור $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$ (כלומר X בעל שונות). נחפש $Y \in L^2(\Omega, \mathcal{G}, \mathbb{P})$ שממזער את $\mathbb{E}((X - Y)^2)$, זאת שכן $a = \mathbb{E}(X)$ ממזער את $\mathbb{E}((X - a)^2)$. קיים Y כזה כי זהו תת-מרחב הילברט. Y הוא ההטלה של X על $L^2(\Omega, \mathcal{G}, \mathbb{P})$, כלומר $X - Y$ מאונך למרחב $L^2(\Omega, \mathcal{G}, \mathbb{P})$, דהינו,

$$\forall Z \in L^2(\Omega, \mathcal{G}, \mathbb{P}), \quad Z \perp X - Y \iff \langle Z, X - Y \rangle = \mathbb{E}(Z(X - Y)) = 0$$

בפרט אם ניקח $Z = \mathbb{1}_A$ עבור $A \in \mathcal{G}$ נקבל,

$$\mathbb{E}(X \mathbb{1}_A) = \mathbb{E}(Y \mathbb{1}_A)$$

9.3 מרטינגלים ותוחלת מותנית

תהי $\{\mathcal{F}_n\}_{n=1}^\infty$ פילטרציה (סדרה עולה של תת- σ -אלגברות) ו- X_n סדרת משתנים מקריים

הגדרה 9.4 (מרטינגל כללי) X_n הוא מרטינגל ביחס ל- $\mathcal{F}_n$ אם,

1. X_n מותאם ל- $\mathcal{F}_n$, כלומר X_n הוא $\mathcal{F}_n$ -מדיד

2. $\mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n$ לכל n .

הערה אם $\mathcal{F}_n = \sigma(X_0, \dots, X_n)$ בדידים אז מקבלים את ההגדרה המקורית.

כדי לראות זאת נגדיר $\{A_i\}_{i \in I}$ עבור $|I| \leq \aleph_0$ חלוקה, כלומר $\cup_{i \in I} A_i = \Omega$. נגדיר $\mathcal{G} = \sigma(\{A_i\}_{i \in I})$, ויהי X משתנה מקרי בעל-תוחלת ונגדיר,

$$Y|_{A_i} \equiv \mathbb{E}(X | A_i) = \frac{\mathbb{E}(X \mathbb{1}_{A_i})}{\mathbb{P}(A_i)}$$

אז $Y = \mathbb{E}[X | \mathcal{G}]$ בדיוק.

נעבור לתכונות.

טענה 9.5 נניח ש- $(\Omega, \mathcal{F}, \mathbb{P})$ מרחב הסתברות, $\mathcal{G} \subseteq \mathcal{F}$ תת- σ -אלגברה ו- $X, Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ אז מתקיים:

1. נוסחת התוחלת השלמה: $\mathbb{E}(\mathbb{E}[X | \mathcal{G}]) = \mathbb{E}(X)$

2. אם X הוא $\mathcal{G}$ -מדיד אז $\mathbb{E}[X | \mathcal{G}] = X$

3. לינאריות: $\mathbb{E}[X + Y | \mathcal{G}] = \mathbb{E}[X | \mathcal{G}] + \mathbb{E}[Y | \mathcal{G}]$

4. אם $X \geq 0$ כמעט-תמיד אז $\mathbb{E}[X | \mathcal{G}] \geq 0$ כמעט-תמיד

5. אי-שוויון יאנסן: אם $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ קמורה אז,

$$\varphi(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[\varphi(X) | \mathcal{G}]$$

6. אם $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$ אז,

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}]$$

7. הוצאת המוכר (Taking out what is known): אם Z הוא $\mathcal{G}$ -מדיד אז,

$$\mathbb{E}[XZ | \mathcal{G}] = Z \cdot \mathbb{E}[X | \mathcal{G}]$$

8. אי־תלות: אם X בלתי־תלוי ב־ $\mathcal{G}$ אז $\mathbb{E}[X | \mathcal{G}] \stackrel{a.s.}{=} \mathbb{E}(X)$

9. אם $X_n > 0$ ו־ $X_n \nearrow X$ כמעט־תמיד אז,

$$\mathbb{E}[X_n | \mathcal{G}] \nearrow \mathbb{E}[X | \mathcal{G}]$$

10. אם $X \xrightarrow{a.s.} X_n$ וגם קיים $Z \in L^1$ כך שלכל n , $|X_n| \leq Z$, אז,

$$\mathbb{E}[X_n | \mathcal{G}] \rightarrow \mathbb{E}[X | \mathcal{G}]$$

11. אם $X_n \geq 0$ אז,

$$\mathbb{E}[\liminf_{n \rightarrow \infty} X_n | \mathcal{G}] \leq \liminf \mathbb{E}[X_n | \mathcal{G}]$$

דוגמה 9.6 יהי $X \in L^1$ ו־ $\mathcal{F}_n$ פילטרציה ונגדיר, אז,

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] = \mathbb{E}[\mathbb{E}[X | \mathcal{F}_{n+1}] | \mathcal{F}_n] = \mathbb{E}[X | \mathcal{F}_n] = X_n$$

באופן כללי נקבל שעבור מרטינגל,

$$\mathbb{E}[X_{n+2} | \mathcal{F}_n] = \mathbb{E}[\mathbb{E}[X_{n+2} | \mathcal{F}_{n+1}] | \mathcal{F}_n] = \mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n$$

מסקנה 9.6 אם $X_0 = x_0$ כמעט תמיד אז,

$$\mathbb{E}(X_n) = x_0$$

17.6.2026 – 10 שיעור 10

10.1 מרטינגלים

אם $\{A_k\}_{k \in \mathbb{N}}$ חלוקה של Ω ו- $A_k \in \mathcal{F}$, נסמן $G = \sigma(A_1, A_2, \dots)$. משתנה-מקרי בעל תוחלת ונסמן,

$$a_k = \mathbb{E}(X \mid A_k) = \frac{\mathbb{E}(X \mathbb{1}_{A_k})}{\mathbb{P}(A_k)}$$

לכל $\omega \in A_k$ נגדיר $Z(\omega) = a_k$.

טענה 10.1 $Z = \mathbb{E}[X \mid G]$, ו- Z הוא G -מדיד כי,

$$G \in \bigcup_{a_k \in B} A_k = Z^{-1}(B)$$

הגדרה 10.2 (תהליך צפוי) תהליך $\{C_n\}_{n \in \mathbb{N}}$ נקרא צפוי ביחס לפילטרציה $\mathcal{F}_n$ אם C_n הוא $\mathcal{F}_n$ -מדיד לכל n .

הגדרה 10.3 אם X_n הוא מרטינגל ו- C_n צפוי (ביחס ל- $\mathcal{F}_n$) נגדיר,

$$Y_n = (C \cdot X)_n = \sum_{k=1}^n C_k(X_k - X_{k-1})$$

טענה 10.4 Y_n הוא מרטינגל.

הוכחה.

$$\begin{aligned} \mathbb{E}[Y_{n+1} \mid \mathcal{F}_n] &= \mathbb{E}[Y_n + C_{n+1}(X_{n+1} - X_n) \mid \mathcal{F}_n] \\ &= \mathbb{E}[Y_n \mid \mathcal{F}_n] + \mathbb{E}[C_{n+1}(X_{n+1} - X_n) \mid \mathcal{F}_n] \\ &= Y_n + C_{n+1} \mathbb{E}[X_{n+1} - X_n \mid \mathcal{F}_n] \\ &= Y_n + C_{n+1}(\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] - \mathbb{E}[X_n \mid \mathcal{F}_n]) \\ &= Y_n \end{aligned}$$

□

נגדיר עבור זמן עצירה $\tau : \Omega \rightarrow \mathbb{N}$ את,

$$Y_n = X_{\min(\tau, n)}$$

טענה 10.5 Y_n מרטינגל.

הוכחה.

$$C_n = \mathbb{1}_{\{\tau \geq n\}} = 1 - \mathbb{1}_{\{\tau \leq n-1\}}$$

כלומר C_n הוא $\mathcal{F}_{n-1}$ -מדיד, כלומר צפוי. אז,

$$Y_n = X_{\min\{\tau, n\}} = \sum_{k=1}^n \mathbb{1}_{\{\tau \geq k\}}(X_k - X_{k-1})$$

כי אם $\tau(\omega) \geq n$ נקבל,

$$X_n - X_0 = \sum_{k=1}^n X_k - X_{k-1}$$

ואם $\tau(\omega) \leq n$ אז,

$$X_\tau - X_0 = \sum_{k=1}^{\tau(n)} X_k - X_{k-1}$$

□

ובסך-הכול קיבלנו את המבוקש.

טענה 10.6 X_n תהליך ו- τ זמן עצירה כך ש- $\tau < \infty$ כמעט-תמיד אז,

$$X_{\min\{\tau, n\}} \xrightarrow{a.s.} X_\tau$$

הוכחה. לכל ω עבורו $\tau(\omega) < \infty$ מתקיים,

$$\min\{\tau(\omega), n\} \rightarrow \tau(\omega)$$

□

משפט 10.7 (Doob's Optional Stopping) יהי X_n מרטינגל ו- τ זמן עצירה (ביחס ל- $\mathcal{F}_n$), אז מתקיים אחד מהבאים:

1. $\tau \leq k$ כמעט-תמיד עבור $k \in \mathbb{N}$ כלשהו

2. $\tau < \infty$ כמעט-תמיד ומתקיים,

$$|X_{\min(\tau, n)}| \leq M$$

כמעט-תמיד לאיזשהו M

3. $\mathbb{E}(\tau) < \infty$ ומתקיים,

$$|X_{\min(\tau, n+1)} - X_{\min(\tau, n)}| \leq M$$

כמעט-תמיד לאיזשהו M אז $\mathbb{E}(X_\tau) = 0$

הוכחה. נסמן $Y_n = X_{\min(\tau, n)}$ והראינו שזהו מרטינגל. גם ראינו ש- $Y_n \rightarrow X_\tau$ כמעט-תמיד, ובנוסף $\mathbb{E}(Y_n) = 0$.

עבור 1 $X_\tau = Y_k$ (עבור k שחוסם את τ). עבור 2 Y_n חסום ולפי משפט ההתכנסות החסומה נקבל $\mathbb{E}(X_\tau) \rightarrow \mathbb{E}(Y_n)$. עבור 3,

$$X_{\min(\tau, n)} = \sum_{k=1}^n X_{\min(\tau, k)} - X_{\min(\tau, k-1)} \leq \sum_{k=1}^n |X_{\min(\tau, k)} - X_{\min(\tau, k-1)}| \leq M \min(\tau, n)$$

ולכן Y_n נשלטת על-ידי $M\tau$ שבעלת תוחלת סופית ולפי משפט ההתכנסות הנשלטת נקבל $\mathbb{E}(Y_n) \rightarrow \mathbb{E}(X_\tau)$.

□

יהי מרטינגל על $\mathbb{Z}$ עם $X_0 = 0$ וכן,

$$\tau = \min\{t \mid X_t \in \{-a, b\}\}$$

עבור $a, b \in \mathbb{N}$. בהתאם,

$$\mathbb{P}(\tau_b < \tau_a) = \frac{a}{a+b}$$

אז נגדיר $Y_n = X_n^2 - n$

$$\mathbb{E}[Y_n \mid \mathcal{F}_n] = \mathbb{E}[X_{n+1}^2 - n \mid \mathcal{F}_n] = \mathbb{E}[(X_n + Z_{n+1})^2 \mid \mathcal{F}_n] - n - 1 = \mathbb{E}[X_n^2 + 2X_n Z_{n+1} + Z_{n+1}^2 \mid \mathcal{F}_n] - n - 1$$

29.6.2026 – 12 שיעור 11

11.1 מרטינגלים – המשך

דיברנו על מרטינגלים, אשר מקיימים $\mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n$ ודיברנו על זמן עצירה $\tau : \Omega \rightarrow \mathbb{N}$ שמקיימת תמיד $\{\tau = k\} \in \mathcal{F}_k$. לבסוף הגענו למשפט העצירה האופציונלית.

מסקנה 11.1 אם P שרשרת-מרקוב נשנית אז היא ליובל, כלומר אין פונקציות הרמוניות חסומות ולא קבועות, כלומר אין פונקציה h שמקיימת $Ph = h$, או במילים אחרות,

$$\sum_y P(x, y)h(y) = h(x)$$

אם נסמן $Y_n = h(X_n)$ נקבל,

דוגמה 11.1 אם X_n הילוך מקרי פשוט על $\mathbb{Z}^d$ ו- h פונקציה הרמונית חסומה, ונגדיר $X_0 = (0, \dots, 0)$ ו- $Y_0 = (2, 0, \dots, 0)$. נראה ש- h קבועה, כלומר ששרשרת מרקוב זו היא ליובל. נניח ש- Z_n סדרת וקטורים בלתי-תלויים המקיימים,

$$Z_n \sim U(\pm e_i)$$

ולכן $X_{n+1} = X_n + Z_{n+1}$ ומתקיים,

$$Y_{n+1} = Y_n + \mathbb{1}_{X_n=Y_n} Z_{n+1} - \mathbb{1}_{X_n \neq Y_n} Z_{n+1}$$

בהתאם $h(X_n)$ הוא מרטינגל ולכן גם $h(Y_n)$ ונקבל,

$$\mathbb{E}(h(X_\tau)) = \mathbb{E}(h(X_0)) = h((0, \dots, 0))$$

נניח ש- X_n מרטינגל ולכן $\mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n$. המטרה שלנו כרגע היא להראות קיום של X_∞ כך ש- $X_n \xrightarrow{\text{a.s.}} X_\infty$. יהיו $a < b$ כלשהם, ונגדיר $U_N(a, b)$ בתור מספר החציות כלפי מעלה של הקטע $[a, b]$. עבור k כך שקיימים זמנים $0 \leq s_1 < t_1 < s_2 < t_2 < \dots < s_k < t_k \leq N$ עבורם,

$$\forall i \leq k, X_{s_i} \leq a, \quad \forall i \leq k, X_{t_i} \geq b$$

אז $U_N(a, b)$ סדרה עולה של משתנים-מקריים מתאימה ל- $\mathcal{F}_n$.

טענה 11.2 אם נסמן $x^- = \max(-a, 0)$ אז מתקיים,

$$\mathbb{E}(U_N(a, b)) \leq \frac{\mathbb{E}((X_N - a)^-)}{b - a}$$

הוכחה. X_s מרטינגל ונגדיר,

$$Y_n = \sum_{i=1}^n C_i(X_n - X_{n-1})$$

כאשר C_n צפוי (C_n הוא $\mathcal{F}_{n-1}$ -מדיד לכל n). נקבל ש- Y_n הוא מרטינגל.

נגדיר $C_1 = \mathbb{1}_{X_0 \leq a}$ וקורסיבית,

$$C_n = \mathbb{1}_{C_{n-1}=1} \cdot \mathbb{1}_{X_{n-1} < a} + \mathbb{1}_{C_{n-1}=0} \cdot \mathbb{1}_{X_{n-1} \leq a}$$

אז Y_n הוא אכן מרטינגל. נחשב,

$$\begin{aligned} Y_N &= \sum_{i=1}^k \sum_{n=s_{i-1}}^{t_i} X_n - X_{n-1} + \mathbb{1}_{s_{k+1} \leq N} \sum_{n=s_{k+1}}^N X_n - X_{n-1} \\ &= \sum_{i=1}^k X_{t_i} - X_{s_i} + \mathbb{1}_{s_{k+1} \leq N} (X_N - X_{s_{k+1}}) \\ &\geq \sum_{i=1}^k (b - a) + \mathbb{1}_{s_{k+1} \leq N} (X_N - X_{s_{k+1}}) \end{aligned}$$

וכן,

$$0 = \mathbb{E}(Y_N) \geq (b-a)\mathbb{E}(U_N(a,b)) + \mathbb{E}(\mathbb{1}_{s_{k+1} \leq N}(X_N - X_{s_{k+1}}))$$

אבל,

$$\mathbb{E}(U_N(a,b)) \leq \frac{-\mathbb{E}(\mathbb{1}_{s_{k+1} \leq N}(X_N - X_{s_{k+1}}))}{b-a}$$

ולאחר העברות אנפים,

$$\mathbb{E}(\mathbb{1}_{s_{k+1} \leq N}(X_N - X_{s_{k+1}}))\mathbb{E}(\mathbb{1}_{s_{k+1} \leq N}(a - X_N))\mathbb{E}(\mathbb{1}_{s_{k+1} \leq N}(a - X_N)^+)\mathbb{E}((a - X_N)^+)|a| + \mathbb{E}(|X_N|)$$

אם $M \leq \mathbb{E}(|X_N|)$ לכל N אז $\mathbb{E}(U_N(a,b))$ חסומה ואחידה ו- $U_N(a,b)$ סדרה עולה ולכן,

$$U_N(a,b) \rightarrow U_\infty(a,b)$$

עם תוחלת סופית ולכן סופי כמעט-תמיד, לכן X_n מתכנס. בפרט מרטינגל חסום כמעט-תמיד מתכנס וגם מרטינגל אי-שלילי מתכנס. $\square$

11.3 הגדרה (עוד התכנסויות) $X_n \xrightarrow{d} X_\infty$ אם $F_{X_n}(a) \xrightarrow{n \rightarrow \infty} F_{X_\infty}(a)$ לכל a שהיא נקודת אי-רציפות של F_{X_∞} כאשר $F_X(a) = \mathbb{P}(X \leq a)$

$X_n \xrightarrow{w} X_\infty$ אם $\mathbb{E}(h(X_n)) \rightarrow \mathbb{E}(h(X_\infty))$ לכל h רציפה וחסומה.

11.4 טענה אם $X_n \xrightarrow{d} X_\infty$ אז $X_n \xrightarrow{w} X_\infty$ אם ורק אם $\mathbb{E}(X_n) \rightarrow \mathbb{E}(X_\infty)$.

11.5 הגדרה (ייצוג סקורחוב) נניח $F : \mathbb{R} \rightarrow [0, 1]$ שהיא מונוטונית עולה חלש, רציפה מימין ו- $F(x) \xrightarrow{x \rightarrow -\infty} 0$ ו- $F(x) \xrightarrow{x \rightarrow \infty} 1$.

11.6 טענה קיים משתנה מקרי X כך ש- $F \equiv F_X$.

הוכחה. נוכיח את המקרה הפרטי בו היא רציפה ומונוטונית עולה ממש. במקרה זה F היא הפיכה מ- $(0, 1)$ ל- $\mathbb{R}$ והפונקציה ההופכית $G : (0, 1) \rightarrow \mathbb{R}$ היא המשתנה המקרי הרצוי, נראה זאת. נגדיר $\Omega = [0, 1]$ עם מידה אחידה, ותהי $Y \sim U[0, 1]$ אז,

$$\mathbb{P}(G(Y) \leq a) \mathbb{P}(Y \leq F(a)) = F(a) - 0$$

כלומר מצאנו שבמקרה זה קל מאוד לבנות משתנה מקרי מתאים. $\square$

11.7 טענה $F_h(a) \rightarrow F_\infty(a)$ לכל a נקודות רציפות של F_∞ ו- X_n, X_∞ ייצוגי סקורחוב שלכם (עם אותו Y) אז $X_n \xrightarrow{a.s.} X_\infty$.

11.8 משפט (משפט הגבול המרכזי) X_n משתנים-מקריים שוויהתפלגות בלתי-תלויים עם תוחלת 0 ושונות 1 אז,

$$Z_n = \frac{\sum_{i=1}^n X_i}{\sqrt{n}} \xrightarrow{d/w} Z \sim N(0, 1)$$

נתחיל בסקיצה כללית מאוד להוכחה, אותה נמשיך לפתח בהמשך.

הוכחה. נזכר בפונקציות יוצרות מומנטים,

$$M_X(t) = \mathbb{E}(e^{tX})$$

אם X ו- Y בלתי-תלויים אז,

$$M_{X+Y}(t) = \mathbb{E}(e^{t(X+Y)}) = \mathbb{E}(e^{tX})\mathbb{E}(e^{tY}) = M_X(t)M_Y(t)$$

אם $a \in \mathbb{R}$ אז,

$$M_{aX}(t) = \mathbb{E}(e^{taX}) = M_X(at)$$

נטען את הטענה (שיש להוכיח שמתקיים),

$$e^{tX} = 1 + tX + \frac{(tX)^2}{2} + \dots$$

ולכן,

$$M_X(t) = 1 + \mathbb{E}(X)t + \mathbb{E}(X^2)\frac{t^2}{2} + \dots$$

בפרט נובע,

$$M'_X(0) = \mathbb{E}(X), M''_X(0) = \mathbb{E}(X^2), \dots$$

נעבור לחישוב עבור Z_n ,

$$M_{Z_n}(t) = M_{\sum_{i=1}^n X_i}\left(\frac{t}{\sqrt{n}}\right) = \left(M_{X_1}\left(\frac{t}{\sqrt{n}}\right)\right)^n$$

נקבל שגם,

$$M_{X_1}(t) = 1 + \mathbb{E}(X_1)t + \mathbb{E}(X_1^2)\frac{t^2}{2} + o(t^2) = 1 + \frac{t^2}{2} + o(t^2)$$

ומשילוב שני השוויונות האחרונים,

$$\left(M_{X_1}\left(\frac{t}{\sqrt{n}}\right)\right)^n = \left(1 + \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)\right)^n \rightarrow e^{\frac{t^2}{2}}$$

נחשב ונקבל,

$$\mathbb{E}(e^{itZ}) = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{s^2}{2}} \cdot e^{its} ds = e^{\frac{t^2}{2}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{s^2 - 2ts + t^2}{2}\right) ds$$

וזו בדיוק הצפיפות של $N(t, 1)$.

נגדיר את הפונקציה האופיינית $\varphi_X(t) = \mathbb{E}(e^{itX})$, כלומר $\text{Im } \varphi_X \subseteq S^1$. כל התכונות שמצאנו על M_X עדיין חלות על φ_X . גם את φ_X אפשר לפתח עם טיילור,

$$\varphi_X(t) = \mathbb{E}\left(1 + itX + \frac{(itX)^2}{2} + \dots\right) = 1 + i\mathbb{E}(X)t - \mathbb{E}(X^2)\frac{t^2}{2} + o(t^2)$$

אם נחזור על ההוכחה הקודמת עם φ נקבל הפעם,

$$\varphi_{X_1}(t) = 1 - i\frac{t^2}{2} + o(t^2)$$

ולכן גם,

$$\varphi_{Z_n}(t) = e^{-\frac{t^2}{2}}$$

ואז מתקבל,

$$\mathbb{E}(e^{itZ}) = e^{-\frac{t^2}{2}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{s^2 - 2its - t^2}{2}\right) ds$$

ונקבל את הצפיפות של $N(it, 1)$, למרות שזוהי לא התפלגות אפשרית או מוגדרת. □

ההוכחה אומנם לא שלמה אבל משפט זה מסיים את הגרסה שלה שראינו.

משפט 11.9 (ההיפוך של לוי) φ_X קובעת את התפלגות X .

משפט 11.10 (הרציפות של לוי) להשלים

דוגמה 11.2 אם $X \sim U(\{\pm 1\})$ אז,

$$\varphi_X(t) = \frac{1}{2}e^{it} + \frac{1}{2}e^{-it} = \cos t$$

מכך נובע שלא קיימים X ו- Y שווי-התפלגות בלתי-תלויים כך ש- $X - Y \sim U(\{\pm 1\})$ (תרגיל).

דוגמה 11.3 אם $X \sim \text{Exp}(1)$ אז,

$$\varphi_X(t) = \int_0^\infty e^{itr} \cdot e^{-r} dr = \int_0^\infty e^{r(it-1)} dr = \frac{e^{r(it-1)}}{it-1} \Big|_{r=0}^{r=\infty} = \frac{1}{1-it}$$

דוגמה 11.4 הפעם נגדיר $f_X(r) = \frac{1}{2}e^{-|r|}$, והפעם נקבל באופן דומה לדוגמה הקודמת,

$$\varphi_X(t) = \frac{1}{2} \frac{1}{1-it} + \frac{1}{2} \frac{1}{1+it} = \frac{1}{(1-it)(1+it)} = \frac{1}{1+t^2}$$

מתהליך זה נוכל למצוא נוסחה לחישוב התפלגות.

טענה 11.11 אם φ_X היא ב- L^1 אז X משתנה-מקרי רציף בהחלט ואף,

$$f_X(a) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-ita} \varphi_X(t) dt$$

נובע אם כך שאם $f_X(r) = \frac{1}{\pi(1+r^2)}$ בדיוק כמו בדוגמה האחרונה אז,

$$\varphi_X(t) = \frac{1}{2}e^{-|t|}$$

להתפלגות זו קוראים התפלגות קושי, או יותר נכון זוהי גרסה פרטית שלה, והיא מקיימת את התכונה הבאה,

טענה 11.12 אם X ו- Y מתפלגים קושי ובלתי-תלויים אז,

$$\frac{X+Y}{2}$$

מתפלג קושי.

זוהי תכונה ייחודית, שכן היא מאלצת משיקולי הגדרת התוחלת שלא יהיה אפשרי שתהיה תוחלת, בפרט גם אין שונות, שכן נוכל לקחת ממוצע של משתנה מקרי כזה עם עצמו. התפלגות קושי והתפלגות נורמלית הן דוגמות להתפלגויות יציבות, כלומר שאם ממצעים אותן ומחלקים ב- n^α הן נשארות זהות.

הגדרות ומשפטים

4	הגדרה 1.1 (הילוך מקרי פשוט על גרף)
5	הגדרה 2.1 (אלגברה)
5	הגדרה 2.2 (מרחב מדיד)
5	הגדרה 2.3 (סיגמא-אלגברה נוצרת)
5	הגדרה 2.4 (מידת הסתברות)
5	משפט 2.5 (ההרחבה של קרתאודורי)
5	הגדרה 2.6 (גבול עליון ותחתון של מאורעות)
6	הגדרה 2.9 (אי-תלות של מאורעות)
6	הגדרה 2.10 (אי-תלות סיגמא-אלגברה)
6	הגדרה 2.11 (אי-תלות קבוצת סיגמא-אלגברות)
6	הגדרה 2.12 (סיגמא-אלגברת זנב)
7	משפט 2.13 (חוק 0,1 של קולמוגורוב)
8	משפט 3.2 (אינווריאנטיות להזזה בהסתברות)
10	הגדרה 4.1 (התכנסות כמעט תמיד)
10	הגדרה 4.2 (התכנסות בהסתברות)
10	משפט 4.3 (התכנסות תוחלת)
10	הגדרה 4.6 (מטריקה על משתנים מקריים)
10	משפט 4.9 (החוק החזק של המספרים הגדולים)
11	משפט 4.10 (החוק החזק של המספרים הגדולים)
14	הגדרה 5.1 (פולינום ברנשטיין)
16	הגדרה 6.1 (שרשרת מרקוב)
16	הגדרה 6.2 (סטציונרית)
18	הגדרה 7.1 (איברים ניתנים להגעה)
18	הגדרה 7.2 (שרשרת אי-פריקה)
18	משפט 7.3 (יחידות התפלגות אי-פריקה)
18	משפט 7.7
19	הגדרה 7.8 (גרף קיילי)
20	הגדרה 8.2 (צימוד)
21	הגדרה 8.4 (פילטרציה)
21	הגדרה 8.5 (הפילטרציה הטבעית)
21	הגדרה 8.6 (זמן עצירה)
21	הגדרה 8.7 (מאורעות שנגמרים אחרי זמן סופי)
21	משפט 8.8 (תכונת מרקוב החזקה)
22	הגדרה 9.1 (מרטינגל)
23	הגדרה 9.3 (תוחלת מותנית)
23	הגדרה 9.4 (מרטינגל כללי)
25	הגדרה 10.2 (תהליך צפוי)
25	הגדרה 10.3
26	משפט 10.7 (Doobs Optional Stopping)
28	הגדרה 11.3 (עוד התכנסויות)
28	הגדרה 11.5 (ייצוג סקורחוב)
28	משפט 11.8 (משפט הגבול המרכזי)

משפט 11.9 (ההיפוך של לוי)	29
משפט 11.10 (הרציפות של לוי)	29